

局部敏感哈希的下界

Rajeev Motwani*

斯坦福大学

Stanford, CA 94305-9045

rajeev@cs.stanford.edu

Assaf Naor

微软研究院

Redmond WA, 98052-6399

anaor@microsoft.com

Rina Panigrahy†

斯坦福大学

Stanford, CA 94305-9045

rinap@cs.stanford.edu

摘要

给定一个度量空间 (X, d_X) , $c \geq 1$, $r > 0$, 以及 $p, q \in [0, 1]$, 若一个映射分布 $H : X \rightarrow \mathbb{N}$ 满足: X 中任意两个距离至多为 r 的点被 H 映到同一个值的概率至少为 p , 并且任意两个距离大于 cr 的点被 H 映到同一个值的概率至多为 q , 则称其为一个 (r, cr, p, q) -敏感哈希族。这个概念由 Indyk 和 Motwani 于 1998 年提出, 作为一种高效近似最近邻搜索算法的基础, 此后已经为这一目的被广泛使用。这些算法的性能由参数

$$\rho = \frac{\log(1/p)}{\log(1/q)}$$

控制, 并且构造具有小 ρ 的哈希族会自动产生改进的最近邻算法。这里我们证明, 对于 $X = \ell_1$, 不可能达到 $\rho \leq \frac{1}{2c}$ 。这几乎匹配 Indyk 和 Motwani 的构造, 该构造达到 $\rho \leq \frac{1}{c}$ 。

类别与主题描述

G.3 [概率与统计]: 概率算法; E.1 [数据结构]: 杂项

一般术语

算法, 理论

关键词

最近邻搜索, 局部敏感哈希, 下界

有大量文献, 我们在此不试图讨论它。关于最近邻问题的背景, 我们把感兴趣的读者引向论文 [6, 5, 4, 7], 尤其是这些论文中的参考文献。

虽然精确最近邻问题看起来遭受“维数灾难”的影响, 但已经设计出了许多高效技术来寻找近似解, 其到查询点的距离至多为最近邻距离的 c 倍。近似最近邻搜索中最通用且高效的方法之一基于局部敏感哈希, 这是由 Indyk 和 Motwani 于 1998 年在 [6] 中引入的。这个方法已经在若干论文中被精炼和改进, 最新的算法可以在 [4] 中找到。我们还把读者引向 LSH 网站, 在那里可以找到关于这个算法的更多信息, 包括其实现和代码; 所有这些可以在 <http://web.mit.edu/andoni/www/LSH/index.html> 找到。

近似最近邻问题的 LSH 方法基于如下概念。

定义 1. 设 (X, d_X) 是一个度量空间, $r, R > 0$ 且 $p, q \in [0, 1]$ 。若一个映射分布 $H : X \rightarrow \mathbb{N}$ 满足对于任意 $x, y \in X$,

$$d_X(x, y) \leq r \Rightarrow \Pr_H[H(x) = H(y)] \geq p,$$

$$d_X(x, y) > R \Rightarrow \Pr_H[H(x) = H(y)] \leq q,$$

则称其为一个 (r, R, p, q) -敏感哈希族。

给定 $c \geq 1$ 和 $q \in (0, 1)$, 我们定义 $\rho_X(c, q)$ 为最小的常数 $\rho > 0$, 使得对每个 $r > 0$, 存在 $p \in (0, 1)$ 和一个 (r, cr, p, q) -敏感哈希族 $H : X \rightarrow \mathbb{N}$, 且

$$\frac{\log(1/p)}{\log(1/q)} \leq \rho.$$

换句话说,

$$\rho_X(c, q) = \sup_{r>0} \inf \left\{ \frac{\log(1/p)}{\log(1/q)} : \exists H : X \rightarrow \mathbb{N} \text{ 为 } (r, cr, p, q)\text{-敏感哈希族} \right\}. \quad (1)$$

特别令人感兴趣的是 $X = \ell_s^d$ 的情形, 其中 $s > 0$ 且 $d \in \mathbb{N}$ 。这里以及下文中, ℓ_s^d 表示赋有 ℓ_s 范数的空间 $\mathbb{R}^d$,

$$\|(x_1, \dots, x_d)\|_s = (|x_1|^s + \dots + |x_d|^s)^{1/s}$$

1 引言

在这篇短文中, 我们研究使用局部敏感哈希 (Locality Sensitive Hashing, LSH) 在某些高维空间中寻找查询点的最近邻的复杂度。最近邻问题表述如下: 给定度量空间中的一个包含 n 个点的数据库, 对它进行预处理, 使得给定一个新的查询点时, 可以快速找到数据集中离它最近的点。这个基础问题出现在大量应用中, 包括数据挖掘、信息检索以及图像搜索, 在这些应用中, 对象的有区分性的特征被表示为 $\mathbb{R}^d$ 中的点。关于这个主题

*受 NSF Grant ITR-0331640 资助。

†受 NSF Grant ITR-0331640 和 Stanford Graduate Fellowship 资助。

(当 $0 < s < 1$ 时这只是一个拟范数)。在这种情况下我们定义

$$\rho_s(c) = \sup_{0 < q < 1} \limsup_{d \rightarrow \infty} \rho_{\ell_s^d}(c, q).$$

这些参数的重要性来自下述对近似最近邻搜索的应用。为了方便，我们将在 c -近似最近邻问题的如下判定版本框架中讨论它：给定一个查询点，在存在一个数据点到该查询点的距离至多为 r 的前提下，找出数据集中任意一个到它距离至多为 cr 的元素。这个判定版本被称为 (r, cr) -近邻问题。众所周知，归约到判定版本只会在时间和空间复杂度中增加一个对数因子 [6, 5]。下述定理在 [6] 中得到证明；这里给出的精确表述取自 [4]。

定理 1. 设 (X, d_X) 是 $\mathbb{R}^d$ 的一个子集上的度量。假设 (X, d_X) 允许一个 (r, cr, p, q) -敏感哈希族 $\mathcal{H}$ ，并记

$$\rho = \frac{\log(1/p)}{\log(1/q)}.$$

则对任意 $n \geq 1/q$ ，存在一个用于 X 的 n 点子集上的 (r, cr) -近邻问题的随机算法，它使用

$$O(dn + n^{1+\rho})$$

空间，查询时间由 $O(n^\rho)$ 次距离计算和

$$O(n^\rho \log_{1/q} n)$$

次来自 $\mathcal{H}$ 的哈希函数求值所支配。

因此，获得关于 $\rho_X(c)$ 的界具有很大的算法意义。在 [6] 中证明了 $\rho_1(c) \leq 1/c$ ，并且对于小的 c 值，即 $c \in [1, 10]$ ，在 [4] 中证明了这个不等式是严格的。关于小 c 时 $\rho_1(c)$ 的最佳已知估计的数值数据，我们参见 [4]。对于 $s = 2$ ，Andoni 和 Indyk [1] 的一个近期结果表明 $\rho_2(c) \leq 1/c^2$ ，而对于一般的 $s \in (0, 2]$ ，最佳已知界 [4] 为

$$\rho_s(c) \leq \max\{1/c, 1/c^s\}.$$

本文的主要目的，是得到关于 $\rho_1(c)$ 和 $\rho_2(c)$ 的下界，这些下界几乎匹配由 [6, 4, 1] 中的构造得到的界。我们的主要结果是：

定理 2. 对每个 $c, s \geq 1$ ，

$$\rho_s(c) \geq \frac{e^{1/c^s} - 1}{e^{1/c^s} + 1} \geq \frac{e - 1}{e + 1} \cdot \frac{1}{c^s} \geq \frac{0.462}{c^s}. \quad (2)$$

(2) 中倒数第二个不等式来自函数 $t \mapsto \frac{e^t - 1}{e^t + 1}$ 在 $[0, \infty)$ 上的凹性。还要观察到，当 $c \rightarrow \infty$ 时，

$$\frac{e^{1/c} - 1}{e^{1/c} + 1} \sim \frac{1}{2c}.$$

精确确定 $\limsup_{c \rightarrow \infty} c \cdot \rho_1(c)$ 将会非常有趣；由于定理 1.3 和 [6] 的结果，我们目前知道这个数位于区间 $[1/2, 1]$ 中。

2 定理 1.2 的证明

定理 1.3 证明中的基本想法很简单。选择一个随机点 $x \in \{0, 1\}^d$ ，并考虑立方体 $\{0, 1\}^d$ 的随机子集 A ，它由满足 $H(u) = H(x)$ 的点 u 组成。定义 1.1 中的第二个条件迫使 A 在期望意义下很小。但是，当 A 很小时，我们可以从上方界定从 A 中的随机点开始的随机游走在 r 步之后最终落在 A 中的概率。我们使用傅里叶分析论证得到这个上界，并且把它与定义 1.1 中的第一个条件结合，从而推出关于 $\rho_1(c)$ 的所需界。

定理 1.3 来自下述结果：

命题 1. 设 $\mathcal{H}$ 是 *Hamming* 立方体 $(\{0, 1\}^d, \|\cdot\|_1)$ 上的一个 (r, R, p, q) -敏感哈希族。假设 r 是奇整数且 $R < d/2$ 。则

$$p \leq \left(q + \exp \left(-\frac{1}{d} \left(\frac{d}{2} - R \right)^2 \right) \right)^{\frac{e^{2r/d} - 1}{e^{2r/d} + 1}}.$$

在命题 2.1 中选择 $R \approx d/2 - \sqrt{d \log d}$ 且 $r \approx R/c$ ，并令 $d \rightarrow \infty$ ，得到 $s = 1$ 情形的定理 1.3。一般的 $s \geq 1$ 情形来自如下事实：对 $x, y \in \{0, 1\}^d$ ，

$$\|x - y\|_s = \|x - y\|_1^{1/s}.$$

注 1. 命题 2.1 对 $(\{0, 1\}^d, \|\cdot\|_1)$ 上任意 (r, cr, p, q) -敏感哈希族的 $\frac{\log(1/p)}{\log(1/q)}$ 给出了一个非平凡下界，即便允许 q 依赖于 d 也是如此。注意，按照 (1) 中给出的定义，定理 1.3 只对常数 q 蕴含这样的下界。但是，命题 2.1 强得多，并且对每个 $q \geq 2^{-o(d)}$ 蕴含一个渐近上与 1.3 中的下界一致的界。

命题 2.1 的证明将被分解为几个引理。

引理 1. 设 $\mathcal{H}$ 是 *Hamming* 立方体 $(\{0, 1\}^d, \|\cdot\|_1)$ 上的一个 (r, R, p, q) -敏感哈希族，并固定 $x \in \{0, 1\}^d$ 。则

$$\mathbb{E} |H^{-1}(H(x))| \leq \sum_{k=0}^{\lfloor R \rfloor} \binom{d}{k} q \cdot \sum_{k=\lfloor R \rfloor + 1}^d \binom{d}{k}.$$

证明。我们简单地写成

$$\begin{aligned} \mathbb{E} |H^{-1}(H(x))| &= \sum_{u \in \{0, 1\}^d} \Pr[H(u) = H(x)] \\ &\leq |\{u \in \{0, 1\}^d : \|u - x\|_1 \leq R\}| \\ &\quad + q \cdot |\{u \in \{0, 1\}^d : \|u - x\|_1 > R\}| \\ &= \sum_{k=0}^{\lfloor R \rfloor} \binom{d}{k} q \cdot \sum_{k=\lfloor R \rfloor + 1}^d \binom{d}{k}, \end{aligned}$$

这就是所需的不等式。 $\square$

推论 1. 假设 $R < d/2$ 。则使用引理 2.2 的记号，我们有

$$\mathbb{E} \frac{|H^{-1}(H(x))|}{2^d} \leq q + \exp \left(-\frac{1}{d} \left(\frac{d}{2} - R \right)^2 \right).$$

证明. 这来自引理 2.2 和标准估计

$$\sum_{k \leq d/2-a} \binom{d}{k} \leq 2^d \cdot e^{-a^2/d}.$$

□

引理 2 (随机游走引理). 设 r 是一个奇整数. 给定 $\emptyset \neq B \subseteq \{0, 1\}^d$, 考虑如下定义的随机变量 $Q_B \in \{0, 1\}^d$: 均匀随机地选择一个点 $z \in B$, 并从 z 开始在 *Hamming* 立方体上执行 r 步标准随机游走. 如此得到的点记为 Q_B . 则

$$\Pr[Q_B \in B] \leq \left(\frac{|B|}{2^d} \right)^{\frac{e^{2r/d}-1}{e^{2r/d}+1}}.$$

证明. 我们首先回忆 *Hamming* 立方体上傅里叶分析的一些背景和记号. 给定 $S \subseteq \{1, \dots, d\}$, Walsh 函数 $W_S: \{0, 1\}^d \rightarrow \{-1, 1\}$ 定义为

$$W_S(u) = (-1)^{\sum_{j \in S} u_j}.$$

对于 $f: \{0, 1\}^d \rightarrow \mathbb{R}$, 我们令

$$\hat{f}(S) = \frac{1}{2^d} \sum_{u \in \{0, 1\}^d} f(u) W_S(u),$$

于是 f 可以分解如下:

$$f = \sum_{S \subseteq \{1, \dots, d\}} \hat{f}(S) W_S.$$

对每个 $f, g: \{0, 1\}^d \rightarrow \mathbb{R}$, 我们写

$$\langle f, g \rangle = \frac{1}{2^d} \sum_{u \in \{0, 1\}^d} f(u) g(u).$$

由 Parseval 恒等式,

$$\langle f, g \rangle = \sum_{S \subseteq \{1, \dots, d\}} \hat{f}(S) \hat{g}(S).$$

对 $\varepsilon \in [0, 1]$, Bonami-Beckner 算子 T_ε 定义为

$$T_\varepsilon f = \sum_{S \subseteq \{1, \dots, d\}} \varepsilon^{|S|} \hat{f}(S) W_S.$$

Bonami-Beckner 不等式 [3, 2] 说明, 对于每个 $f: \{0, 1\}^d \rightarrow \mathbb{R}$,

$$\begin{aligned} \sum_{S \subseteq \{1, \dots, d\}} \varepsilon^{2|S|} \hat{f}(S)^2 &= \|T_\varepsilon f\|_2^2 \\ &= \frac{1}{2^d} \sum_{u \in \{0, 1\}^d} (T_\varepsilon f(u))^2 \\ &\leq \|f\|_{1+\varepsilon^2}^2 \\ &= \left\{ \frac{1}{2^d} \sum_{u \in \{0, 1\}^d} |f(u)|^{1+\varepsilon^2} \right\}^{\frac{2}{1+\varepsilon^2}}. \end{aligned}$$

专门取 $B \subseteq \{0, 1\}^d$ 的示性函数, 我们得到

$$\sum_{S \subseteq \{1, \dots, d\}} \varepsilon^{2|S|} \widehat{\mathbf{1}_B}(S)^2 \leq \left(\frac{|B|}{2^d} \right)^{\frac{2}{1+\varepsilon^2}}. \quad (3)$$

现在, 设 P 为 $\{0, 1\}^d$ 上标准随机游走的转移矩阵, 也就是说, 如果 u 和 v 恰好在一个坐标上不同, 则 $P_{uv} = 1/d$, 否则 $P_{uv} = 0$. 通过直接计算我们有, 对每个 $S \subseteq \{1, \dots, d\}$,

$$P W_S = \left(1 - \frac{2|S|}{d} \right) W_S,$$

也就是说 W_S 是 P 的一个特征向量, 其特征值为 $1 - \frac{2|S|}{d}$. 从 B 中随机点开始的随机游走在 r 步后最终落在 B 中的概率等于

$$\begin{aligned} \Pr[Q_B \in B] &= \frac{1}{|B|} \sum_{a, b \in B} (P^r)_{ab} \\ &= \frac{2^d}{|B|} \langle P^r \mathbf{1}_B, \mathbf{1}_B \rangle \\ &= \frac{2^d}{|B|} \sum_{S \subseteq \{1, \dots, d\}} \widehat{\mathbf{1}_B}(S)^2 \left(1 - \frac{2|S|}{d} \right)^r \\ &\leq \frac{2^d}{|B|} \sum_{\substack{S \subseteq \{1, \dots, d\} \\ |S| \leq d/2}} \widehat{\mathbf{1}_B}(S)^2 \left(1 - \frac{2|S|}{d} \right)^r, \end{aligned}$$

其中我们使用了 r 为奇数这一事实 (即我们丢弃了负项)。

因此, 使用 (3), 我们看到

$$\begin{aligned} \frac{|B|}{2^d} \Pr[Q_B \in B] &\leq \sum_{S \subseteq \{1, \dots, d\}} \widehat{\mathbf{1}_B}(S)^2 e^{-2r|S|/d} \\ &\leq \left(\frac{|B|}{2^d} \right)^{\frac{2}{1+e^{-2r/d}}}. \end{aligned}$$

于是

$$\Pr[Q_B \in B] \leq \left(\frac{|B|}{2^d} \right)^{\frac{1-e^{-2r/d}}{1+e^{-2r/d}}} = \left(\frac{|B|}{2^d} \right)^{\frac{e^{2r/d}-1}{e^{2r/d}+1}},$$

这完成了引理 2.4 的证明. □

命题 2.1 的证明. 假设 r 是奇整数且 $R < d/2$, 并记

$$\alpha = \frac{e^{2r/d}-1}{e^{2r/d}+1}, \quad \beta = q + \exp \left[-\frac{(d/2-R)^2}{d} \right].$$

对 $x \in \{0, 1\}^d$, 令 $W_r(x) \in \{0, 1\}^d$ 为从 x 开始执行 r 步随机游走得到的随机点. 由于 $\|x - W_r(x)\|_1 \leq r$, 我们知道

$$\Pr[H(W_r(x)) = H(x)] \geq p.$$

关于 $\{0,1\}^d$ 上的均匀概率测度取期望, 我们推出

$$\begin{aligned}
p &\leq \mathbb{E}_{x \in \{0,1\}^d} \Pr[H(W_r(x)) = H(x)] \\
&= \mathbb{E}_H \Pr \left[\begin{array}{c} x \in \{0,1\}^d : \\ W_r(x) \in H^{-1}(H(x)) \end{array} \right] \\
&= \mathbb{E}_H \sum_{k \in \mathbb{N}} \Pr \left[\begin{array}{c} x \in \{0,1\}^d : \\ W_r(x) \in H^{-1}(H(x)), H(x) = k \end{array} \right] \\
&= \mathbb{E}_H \sum_{k \in \mathbb{N}} \frac{|H^{-1}(k)|}{2^d} \Pr [Q_{H^{-1}(k)} \in H^{-1}(k)] \\
&\leq \mathbb{E}_H \sum_{k \in \mathbb{N}} \frac{|H^{-1}(k)|}{2^d} \left(\frac{|H^{-1}(k)|}{2^d} \right)^\alpha \\
&= \mathbb{E}_H \mathbb{E}_{x \in \{0,1\}^d} \left(\frac{|H^{-1}(H(x))|}{2^d} \right)^\alpha \\
&\leq \mathbb{E}_{x \in \{0,1\}^d} \left(\mathbb{E}_H \frac{|H^{-1}(H(x))|}{2^d} \right)^\alpha \\
&\leq \beta^\alpha,
\end{aligned}$$

其中第五行使用了引理 2.4, 倒数第二行使用了 Jensen 不等式, 最后一行使用了推论 2.3. $\square$

3 致谢

我们感谢 Piotr Indyk 和 Jirka Matoušek 提出的有益建议。

参考文献

- [1] A. Andoni and P. Indyk. 高维最近邻问题的更快算法。手稿, 2005。
- [2] W. Beckner. 傅里叶分析中的不等式。 *Ann. of Math.* (2), 102(1):159–182, 1975。
- [3] A. Bonami. *Étude des coefficients de Fourier des fonctions de $L^p(G)$* . *Ann. Inst. Fourier (Grenoble)*, 20(fasc. 2):335–402 (1971), 1970。
- [4] M. Datar, N. Immorlica, P. Indyk, and V. S. Mirrokni. 基于 p -稳定分布的局部敏感哈希方案。见 *SCG '04: Proceedings of the Twentieth Annual Symposium on Computational Geometry* (Brooklyn, NY, 2004), 第 253–262 页。ACM Press, New York, NY, 2004。
- [5] S. Har-Peled. 近线性大小 Voronoi 图的替代物。见 *42nd IEEE Symposium on Foundations of Computer Science* (Las Vegas, NV, 2001), 第 94–103 页。IEEE Computer Soc., Los Alamitos, CA, 2001。
- [6] P. Indyk and R. Motwani. 近似最近邻: 迈向消除维数灾难。见 *STOC '98: Proceedings of the Thirtieth*

Annual ACM Symposium on Theory of Computing (Dallas, TX, 1998), 第 604–613 页。ACM Press, New York, NY, 1998。

- [7] R. Panigrahy. 高维中的基于熵的最近邻搜索。见 *SODA '06: Proceedings of the Seventeenth Annual ACM-SIAM Symposium on Discrete Algorithms* (Miami, FL, 2006), 第 1186–1195 页。ACM Press, New York, NY, 2006。