

Lower Bounds on Locality Sensitive Hashing Review

241880622 蒲今

2026 年 7 月 17 日

目录

1	背景与问题定义	2
2	主要定理与贡献	2
3	证明总体思路	3
4	关键技术细节	4
5	正确性与优越性	7
6	与已有及后续工作的比较	8
7	评价、局限与总结	9

1 背景与问题定义

1.1 近似最近邻问题

近似最近邻问题要求：给定一个预处理后的点集 P ，对于查询点 q ，快速找到一个点 $x \in P$ ，使得

$$d(q, x) \leq c \cdot \min_{y \in P} d(q, y),$$

其中 $c > 1$ 是近似因子。当 $c = 1$ 时是精确最近邻；当 $c > 1$ 时，算法允许返回一个足够接近最优答案的点。在高维空间中，精确最近邻通常很难高效解决，因此近似最近邻成为更实际的研究对象。

1.2 LSH 框架与复杂度指数

实际算法通常使用近邻问题的判定版本：在已知数据库中存在点与查询点距离至多为 r 的条件下，返回一个距离至多为 cr 的点。Indyk 和 Motwani 提出的局部敏感哈希 (Locality Sensitive Hashing, LSH) 通过随机哈希使近点更容易碰撞、远点更难碰撞，从而只检查少量候选点 [2]。若近点碰撞概率至少为 p 、远点碰撞概率至多为 q ，则

$$\rho = \frac{\log(1/p)}{\log(1/q)}$$

控制查询复杂度中的指数：查询通常需要约 n^ρ 次距离计算，空间中则出现约 $n^{1+\rho}$ 的项。因此，构造问题是尽量减小 ρ ，而下界问题则要回答：在标准 LSH 模型内， ρ 究竟还能小到什么程度？

1.3 本文评述的问题

本文评述 Motwani、Naor 和 Panigrahy 的 *Lower Bounds on Locality Sensitive Hashing* [1]。论文不提出新的哈希构造，而是首次对整个标准 LSH 模型给出统一的非平凡下界，将“尚未找到更好的算法”推进为“任何满足该模型定义的算法都受到共同限制”。

2 主要定理与贡献

2.1 正式定义

设 (X, d_X) 是一个度量空间。随机哈希函数族 $H : X \rightarrow \mathbb{N}$ 称为 (r, R, p, q) -sensitive，如果对任意 $x, y \in X$ ，有

$$d_X(x, y) \leq r \Rightarrow \Pr_H[H(x) = H(y)] \geq p,$$

并且

$$d_X(x, y) > R \Rightarrow \Pr_H[H(x) = H(y)] \leq q.$$

在近似最近邻问题中通常令 $R = cr$ ，并用

$$\rho = \frac{\log(1/p)}{\log(1/q)}$$

衡量 LSH 的效率。上式中的 ρ 只衡量一个给定哈希族的质量。为了描述度量空间 (X, d_X) 上所有合法哈希族能够达到的最佳指数，进一步定义

$$\rho_X(c) = \sup_{r>0} \inf \left\{ \frac{\log(1/p)}{\log(1/q)} : \begin{array}{l} 0 < p, q < 1, \text{ 且 } X \text{ 上存在一个} \\ (r, cr, p, q)\text{-sensitive 哈希族} \end{array} \right\}.$$

对于高维 ℓ_s 空间，再定义其渐近最佳指数为

$$\rho_s(c) = \limsup_{d \rightarrow \infty} \rho_{\ell_s^d}(c).$$

因此， ρ 是单个哈希族的性能参数，而 $\rho_X(c)$ 和 $\rho_s(c)$ 分别表示在给定空间上对所有合法哈希族优化后的最佳指数，以及该指数在维数趋于无穷时的渐近值。这里 p 越大，说明近点越容易被放到同一个桶中； q 越小，说明远点越不容易误碰撞。因此，一个好的 LSH 需要同时做到“近点高碰撞”和“远点低碰撞”。本文的技术正是围绕这两个要求之间的矛盾展开。

2.2 主定理及适用范围

论文的主定理指出，对任意 $s > 0$ 和 $c > 1$,

$$\rho_s(c) \geq \frac{e^{1/c^s} - 1}{e^{1/c^s} + 1} \geq \frac{0.462}{c^s}.$$

特别地， ℓ_1 与 ℓ_2 空间分别得到 $\Omega(1/c)$ 和 $\Omega(1/c^2)$ 下界。该结论约束的是数据无关的标准 LSH 哈希族，而不是所有近似最近邻数据结构；它也不直接排除数据依赖哈希、图搜索或其他更强模型中的改进。论文的贡献在于首次从 LSH 定义本身推出统一下界，并建立了一套后来可继续加强的 Hamming 立方体分析方法。

3 证明总体思路

3.1 转化到 Hamming 立方体

论文没有直接分析整个高维 ℓ_s^d 空间，而是先分析它的一个特殊子集：

$$\{0, 1\}^d.$$

这个集合是 Hamming 立方体。在该集合上，两个点之间的 ℓ_1 距离等于它们不同坐标的个数。

选择 Hamming 立方体的好处是，它既足够简单，又保留了高维空间的核心困难。立方体中每个点都是一个 0-1 向量，距离就是不同坐标的数量；同时，从一个点出发随机翻转坐标，就得到一个非常自然的随机游走过程。论文正是利用这个随机游走来刻画“从一个点移动到附近点”时哈希值是否仍然相同。

3.2 随机桶与随机游走

第一层是哈希桶分析。固定一个点 x ，并从哈希族 $\mathcal{H}$ 中随机抽取 H ，定义随机桶

$$A_H(x) = H^{-1}(H(x)).$$

这个集合就是 x 在随机哈希函数 H 下所在的桶。远点低碰撞条件说明：如果一个点离 x 很远，那么对 H 的随机性取概率，它落入 $A_H(x)$ 的概率至多是 q 。因此，这一条件限制的是随机桶大小的期望，而不是每一个确定哈希函数所产生的桶大小。

第二层是随机游走分析。论文考虑从点 x 出发，在 Hamming 立方体上随机走 r 步。由于每一步只翻转一个坐标，终点与起点的 Hamming 距离不会超过 r 。先对随机哈希函数使用近点碰撞条件，再对随机游走终点取平均，可知终点以至少 p 的联合概率落入随机桶 $A_H(x)$ 。

3.3 小集合扩散与核心矛盾

第三层是小集合扩散性质。Hamming 立方体上的随机游走会扩散：如果集合 B 很小，那么从 B 中出发的随机游走很难在若干步之后仍然停留在 B 中。这与 LSH 要求的近点高碰撞形成冲突。论文通过傅里叶分析给出这一随机游走概率的上界，并把它与哈希桶大小的上界结合，得到核心不等式

$$p \leq \left(q + \exp \left(-\frac{1}{d} \left(\frac{d}{2} - R \right)^2 \right) \right)^{\frac{e^{2r/d} - 1}{e^{2r/d} + 1}}.$$

这个不等式说明，只要远点碰撞概率 q 很小，近点碰撞概率 p 也会被迫受到限制。最后再把 Hamming 立方体看作 ℓ_s^d 的子集，就可以把该下界推广到高维 ℓ_s 空间。

证明的核心冲突可以概括为

远点低碰撞要求桶不能太大 + 小桶难以困住随机游走 $\Rightarrow$ 近点碰撞概率存在上限。

4 关键技术细节

4.1 第一步：限制哈希桶大小

固定一个点 $x \in \{0,1\}^d$ ，并从哈希族 $\mathcal{H}$ 中随机抽取哈希函数 H ，定义随机桶

$$A_H(x) = H^{-1}(H(x)).$$

集合 $A_H(x)$ 是与 x 哈希到同一个值的所有点。注意，LSH 的碰撞概率是对 $H \sim \mathcal{H}$ 而言的；因此，远点条件控制的是 $|A_H(x)|$ 对随机哈希函数的期望，而不是某个固定 H 的桶大小。

为了估计桶的大小，可以把所有点 $u \in \{0,1\}^d$ 分成两类。第一类是距离 x 不超过 R 的点，它们的数量最多是 Hamming 球的大小

$$\sum_{k=0}^{\lfloor R \rfloor} \binom{d}{k}.$$

对这些点，碰撞概率最多只能粗略地用 1 上界。第二类是距离 x 大于 R 的点。由 LSH 的远点条件，它们与 x 落入同一桶的概率至多是 q 。对所有 u 的碰撞指示变量求和，得到

$$\mathbb{E}_{H \sim \mathcal{H}} |A_H(x)| = \sum_{u \in \{0,1\}^d} \Pr_{H \sim \mathcal{H}} [H(u) = H(x)] \leq \sum_{k=0}^{\lfloor R \rfloor} \binom{d}{k} + q \sum_{k=\lfloor R \rfloor+1}^d \binom{d}{k}.$$

把它除以整个立方体大小 2^d ，就得到桶的平均密度上界。进一步利用 Hamming 球体积估计，当 $R < d/2$ 时，

$$\mathbb{E}_{H \sim \mathcal{H}} \frac{|A_H(x)|}{2^d} \leq q + \exp \left(-\frac{1}{d} \left(\frac{d}{2} - R \right)^2 \right).$$

这里第一项 q 来自远点碰撞概率，第二项来自半径为 R 的 Hamming 球本身在整个立方体中所占的比例。

4.2 第二步：用随机游走连接近点碰撞

在 Hamming 立方体上，从点 x 出发随机翻转一个坐标，重复 r 次，得到随机点 $W_r(x)$ 。由于每一步只改变一个坐标，所以

$$\|x - W_r(x)\|_1 \leq r.$$

因此，对随机游走产生的每一个终点 $y = W_r(x)$ ，近点条件都给出 $\Pr_{H \sim \mathcal{H}}[H(y) = H(x)] \geq p$ 。再对游走终点取平均，得

$$\Pr_{H \sim \mathcal{H}, W_r}[H(W_r(x)) = H(x)] \geq p.$$

这里的概率同时包含两种相互独立的随机性： H 从 $\mathcal{H}$ 中随机抽取， $W_r(x)$ 是随机游走的终点。对任意固定的 H ，碰撞事件等价于 $W_r(x) \in A_H(x)$ ；但 LSH 定义保证的是上述联合概率的下界，并不保证对每个固定的 H ，随机游走都以至少 p 的概率留在桶中。

4.3 第三步：用小集合扩散性质给出上界

Hamming 立方体上的随机游走具有扩散性：如果集合 B 不够大，随机游走从 B 中出发后仍留在 B 中的概率不会太高。论文用 Fourier 分析和 Bonami-Beckner 不等式证明了如下随机游走引理：对任意非空集合 $B \subseteq \{0, 1\}^d$ ，如果 Q_B 表示从 B 中均匀随机选点并走 r 步后的终点，则

$$\Pr[Q_B \in B] \leq \left(\frac{|B|}{2^d} \right)^\alpha, \quad \alpha = \frac{e^{2r/d} - 1}{e^{2r/d} + 1}.$$

这个引理的含义是：桶的相对密度越小，随机游走留在桶中的概率越小。

这里 Fourier 分析的作用，是把“随机游走是否留在集合中”这个组合问题转化为对函数频率成分的估计。具体地说，对集合 B 考虑它的示性函数 $\mathbf{1}_B$ 。在 Hamming 立方体上，任何函数都可以用 Walsh 函数展开：

$$\mathbf{1}_B = \sum_{S \subseteq \{1, \dots, d\}} \widehat{\mathbf{1}_B}(S) W_S.$$

这里 S 可以理解为一组坐标， W_S 描述这些坐标上的奇偶性， $\widehat{\mathbf{1}_B}(S)$ 则表示集合 B 在这种“频率模式”上的权重。

随机游走矩阵 P 对 Walsh 函数的作用非常简单：

$$PW_S = \left(1 - \frac{2|S|}{d} \right) W_S.$$

也就是说，Walsh 函数正好是随机游走的特征向量。经过 r 步随机游走后，频率 S 对应的权重会乘上

$$\left(1 - \frac{2|S|}{d}\right)^r.$$

不能笼统地说所有 $|S|$ 较大的成分都会被快速削弱，因为特征值

$$\lambda_S = 1 - \frac{2|S|}{d}$$

在 $|S|$ 接近 d 时接近 -1 ，其绝对值并不小。正确的处理需要分两部分。当 $|S| \leq d/2$ 时， $\lambda_S \geq 0$ ，且

$$0 \leq \left(1 - \frac{2|S|}{d}\right)^r \leq \exp\left(-\frac{2r|S|}{d}\right),$$

因此这些非负特征值的贡献随 $|S|$ 增大而指数衰减。当 $|S| > d/2$ 时， $\lambda_S < 0$ ；由于论文要求 r 为奇数， λ_S^r 仍为负数，而其前面的 Fourier 系数平方非负，所以这些项在求上界时可以直接丢弃。这正是该证明要求 r 为奇数的实质原因。

于是，随机游走从 B 出发后仍落在 B 中的概率可以写成 Fourier 系数的加权和：

$$\Pr[Q_B \in B] = \frac{2^d}{|B|} \sum_{S \subseteq \{1, \dots, d\}} \widehat{\mathbf{1}_B}(S)^2 \left(1 - \frac{2|S|}{d}\right)^r.$$

接下来需要控制这个加权和。Bonami-Beckner 不等式提供的正是这种控制：当 B 的密度 $|B|/2^d$ 很小时，它的 Fourier 系数不可能让上式过大。换句话说，小集合不能在随机游走下保持太强的稳定性。这一步最终推出

$$\Pr[Q_B \in B] \leq \left(\frac{|B|}{2^d}\right)^{\frac{e^{2r/d}-1}{e^{2r/d}+1}}.$$

4.4 第四步：用 Jensen 不等式闭合上下界

令 x 在 $\{0,1\}^d$ 上均匀分布，并与 H 、随机游走相互独立。条件于固定的 H 和 $H(x) = k$ ，起点 x 在非空桶 $H^{-1}(k)$ 中均匀分布，因而可以对每个桶应用上述随机游走引理。记

$$\alpha = \frac{e^{2r/d} - 1}{e^{2r/d} + 1},$$

则近点碰撞条件和随机游走引理共同给出

$$p \leq \mathbb{E}_H \mathbb{E}_x \left(\frac{|A_H(x)|}{2^d} \right)^\alpha.$$

由于 $0 < \alpha < 1$ ，函数 t^α 为凹函数。Jensen 不等式以及第一步的随机桶密度上界说明

$$\mathbb{E}_H \mathbb{E}_x \left(\frac{|A_H(x)|}{2^d} \right)^\alpha \leq \left(\mathbb{E}_H \mathbb{E}_x \frac{|A_H(x)|}{2^d} \right)^\alpha \leq \left(q + \exp\left(-\frac{(d/2 - R)^2}{d}\right) \right)^\alpha.$$

这就严格闭合了同一碰撞事件的下界与上界，并得到论文的核心命题。

4.5 第五步：从 Hamming 立方体推广到 ℓ_s 空间

由于 $\{0,1\}^d$ 可以看作 ℓ_s^d 的子集，并且在 0-1 向量上距离满足

$$\|x - y\|_s = \|x - y\|_1^{1/s},$$

Hamming 距离上的下界可以转化为 ℓ_s 空间中的下界。最终得到：

$$\rho_s(c) \geq \frac{e^{1/c^s} - 1}{e^{1/c^s} + 1} \geq \frac{0.462}{c^s}.$$

原因是，在 0-1 向量上， ℓ_s 距离等于 Hamming 距离的 $1/s$ 次方。如果在 Hamming 距离中远近阈值的比值是 c^s ，那么在 ℓ_s 距离中对应的比值就是 c 。因此，Hamming 立方体上的下界可以转化为 ℓ_s 空间中的下界。参数选择还需要保证 Hamming 球体积估计中的误差项消失，因此不能只写成 $R \approx d/2$ ，更不能直接取 $R = d/2$ 。一个具体选择是：对于充分大的 d ，取 r_d 为不超过

$$\frac{1}{c^s} \left(\frac{d}{2} - \sqrt{d \log d} \right)$$

的最大奇数，并令 $R_d = c^s r_d$ 。于是

$$R_d = \frac{d}{2} - \sqrt{d \log d} + O(1) = \frac{d}{2} - \Theta(\sqrt{d \log d}), \quad r_d = \frac{R_d}{c^s}.$$

这个选择同时保证 $R_d < d/2$ 、 r_d 为奇数，且

$$\exp\left(-\frac{(d/2 - R_d)^2}{d}\right) = d^{-1+o(1)} \rightarrow 0.$$

另一方面，

$$\frac{2r_d}{d} \rightarrow \frac{1}{c^s},$$

所以随机游走引理中的指数满足

$$\frac{e^{2r_d/d} - 1}{e^{2r_d/d} + 1} \rightarrow \frac{e^{1/c^s} - 1}{e^{1/c^s} + 1}.$$

令 $d \rightarrow \infty$ 后，误差项消失，就得到论文的主定理。

5 正确性与优越性

5.1 证明技术的正确性

证明的正确性首先依赖于对随机性的严格区分。远点条件中的概率来自随机抽取 $H \sim \mathcal{H}$ ，因此它控制的是随机桶 $A_H(x)$ 大小的期望，而不是每个固定哈希函数的桶大小。近点条件同时涉及随机哈希函数和随机游走终点，准确的表述是

$$\Pr_{H \sim \mathcal{H}, W_r} [H(W_r(x)) = H(x)] \geq p.$$

对每个可能的游走终点先应用 LSH 近点条件，再对 W_r 取平均，即可得到该联合概率下界，并未对固定的 H 作额外假设。

其次，证明比较的是同一个碰撞事件。LSH 定义从下方以 p 界定该事件；条件于哈希桶后，随机游走引理和 Bonami–Beckner 不等式从上方界定它。由于

$$0 < \alpha = \frac{e^{2r/d} - 1}{e^{2r/d} + 1} < 1,$$

t^α 的凹性保证 Jensen 不等式的方向正确，从而得到核心命题。最后，所选参数使 Hamming 球误差项趋于零，而 $\{0, 1\}^d \subseteq \ell_s^d$ 及 $\|x - y\|_s = \|x - y\|_1^{1/s}$ 保证子空间下界能够合法推广到整个 ℓ_s^d 。因此，概率空间、上下界比较、极限过程和空间推广四个环节相互衔接，没有引入定义之外的假设。

5.2 证明技术的优越性

这里的“优越性”不是指论文提出了更快的近似最近邻算法，而是指其下界方法具有更强的普适性。对某个具体 LSH 构造的分析只能说明该构造的性能；本文直接从敏感哈希族的定义出发，所以结论同时约束所有数据无关的标准 LSH 哈希族。这把“尚未找到更好的构造”转化为“该模型内不存在数量级更好的构造”。

在定量上，本文对 ℓ_1 和 ℓ_2 分别给出 $\Omega(1/c)$ 与 $\Omega(1/c^2)$ 下界，同当时已知的 $O(1/c)$ 与 $O(1/c^2)$ 上界在渐近量级上匹配。更重要的是，随机桶大小与随机游走稳定性之间的矛盾揭示了下界产生的结构性原因，而不只是给出一个数值不等式。这套 Hamming 立方体、Fourier 分析和噪声稳定性方法也为后续 O’Donnell–Wu–Zhou 的紧下界提供了基础。不过，本文仍存在常数差距，其历史地位和后续改进将在下一章具体比较。

6 与已有及后续工作的比较

6.1 已有上界与本文下界

在本文之前，Indyk 和 Motwani 的构造在 ℓ_1 中达到

$$\rho_1(c) \leq \frac{1}{c}.$$

Datar 等人的 p -稳定分布方法进一步处理了 ℓ_s 空间 [3]，Andoni 和 Indyk 则在 ℓ_2 中得到 $\rho_2(c) \leq 1/c^2$ [4]。这些结果是构造上界；Motwani、Naor 和 Panigrahy 首次给出可与之比较的统一下界。在 ℓ_1 中，本文证明

$$\rho_1(c) \geq \frac{e^{1/c} - 1}{e^{1/c} + 1} \sim \frac{1}{2c} \quad (c \rightarrow \infty).$$

这把差距缩小到常数因子，但并未得到标准数据无关 LSH 的最终紧界。

6.2 O’Donnell–Wu–Zhou 紧下界

O’Donnell、Wu 和 Zhou 后来利用布尔函数噪声稳定性的对数凸性，把 Hamming 空间中的下界提高为

$$\rho \geq \frac{1}{c} - o_d(1)$$

[5]。在 $q \geq 2^{-o(d)}$ （包括固定 q ）的通常范围内，该结果与 $1/c$ 上界匹配，并推出一般 ℓ_s 空间的 $1/c^s - o_d(1)$ 下界，特别是 Euclidean 空间中的紧 $1/c^2$ 下界。因此，本文应评价为开创并奠定了标准 LSH 下界方法，而不是给出了该模型的最终紧常数。

6.3 数据依赖哈希

另一条路线是数据依赖哈希。Andoni 和 Razenshteyn 构造了 Hamming 空间中

$$\rho = \frac{1}{2c-1} + o(1)$$

的方案，Euclidean 空间中的相应指数为 $1/(2c^2 - 1)$ [6]。他们又在限制哈希函数表示复杂度的简洁模型中证明匹配下界；例如 ℓ_1 中有

$$\rho \geq \frac{1}{2c-1} - o(1)$$

[7]。这说明改变模型可以严格优于数据无关 LSH，但新模型也有自己的紧边界。

7 评价、局限与总结

7.1 贡献与方法价值

本文最重要的贡献有两点。第一，它不再逐个分析具体构造，而是直接从“近点高碰撞、远点低碰撞”的定义推出整个标准 LSH 模型的下界。第二，它把算法问题转化为 Hamming 立方体上的小集合扩散问题，以随机桶、随机游走、Fourier 展开和 Bonami–Beckner 不等式形成了一条可复用的证明路线。这种转化既给出定量结论，也解释了下界产生的原因。

7.2 适用范围与局限

论文也有明确局限。其结论只约束数据无关的标准 LSH，并不是所有近似最近邻数据结构的下界；它对数据依赖哈希、图方法及其他计算模型不直接适用。此外，本文在 ℓ_1 中得到的渐近常数约为 $1/2$ ，与已有 $1/c$ 上界仍有常数差距，后来才由 O’Donnell–Wu–Zhou 闭合。最后，主定理是高维渐近结论，不能直接当作有限维实际系统的精确性能预测。

7.3 总结

总体而言，Motwani、Naor 和 Panigrahy 的论文首次证明高维 ℓ_s 空间中的标准 LSH 必须满足

$$\rho_s(c) \geq \frac{e^{1/c^s} - 1}{e^{1/c^s} + 1} = \Omega(1/c^s).$$

它的持久价值不在于最终常数，而在于揭示了随机桶大小与随机游走稳定性之间的结构性矛盾，并为后续紧下界奠定了方法基础。

参考文献

- [1] R. Motwani, A. Naor, and R. Panigrahy. Lower Bounds on Locality Sensitive Hashing. *Proceedings of the Twenty-second Annual Symposium on Computational Geometry*, 2006.
- [2] P. Indyk and R. Motwani. Approximate Nearest Neighbors: Towards Removing the Curse of Dimensionality. *Proceedings of STOC*, 1998.
- [3] M. Datar, N. Immorlica, P. Indyk, and V. S. Mirrokni. Locality-Sensitive Hashing Scheme Based on p-Stable Distributions. *Proceedings of the Twentieth Annual Symposium on Computational Geometry*, 2004.
- [4] A. Andoni and P. Indyk. Faster Algorithms for High-Dimensional Nearest Neighbor Search. Manuscript, 2005.
- [5] R. O’Donnell, Y. Wu, and Y. Zhou. Optimal Lower Bounds for Locality-Sensitive Hashing (Except When q Is Tiny). *Proceedings of ITCS*, 2011.
- [6] A. Andoni and I. Razenshteyn. Optimal Data-Dependent Hashing for Approximate Near Neighbors. *Proceedings of STOC*, 2015.
- [7] A. Andoni and I. Razenshteyn. Tight Lower Bounds for Data-Dependent Locality-Sensitive Hashing. *Proceedings of the 32nd International Symposium on Computational Geometry*, 2016.