

Lower Bounds on Locality Sensitive Hashing Review

241880622 蒲今

2026 年 7 月 17 日

目录

1	背景与问题定义	2
1.1	近似最近邻问题	2
1.2	LSH 框架与复杂度指数	2
1.3	本文评述的问题	2
2	主要定理与贡献	2
2.1	正式定义	2
2.2	主定理及适用范围	3
3	证明总体思路	3
3.1	转化到 Hamming 立方体	3
3.2	随机桶与随机游走	3
3.3	小集合扩散与核心矛盾	4
4	关键技术细节	4
4.1	第一步：限制哈希桶大小	4
4.2	第二步：用随机游走连接近点碰撞	5
4.3	第三步：用小集合扩散性质给出上界	5
4.4	第四步：用 Jensen 不等式闭合上下界	6
4.5	第五步：从 Hamming 立方体推广到 ℓ_s 空间	7
5	与已有及后续工作的比较	7
5.1	已有上界与本文下界	7
5.2	O'Donnell-Wu-Zhou 紧下界	8
5.3	数据依赖哈希	8
6	评价、局限与总结	8
6.1	贡献与方法价值	8
6.2	适用范围与局限	8
6.3	总结	8

1 背景与问题定义

1.1 近似最近邻问题

近似最近邻问题要求：给定一个预处理后的点集 P ，对于查询点 q ，快速找到一个点 $x \in P$ ，使得

$$d(q, x) \leq c \cdot \min_{y \in P} d(q, y),$$

其中 $c > 1$ 是近似因子。当 $c = 1$ 时是精确最近邻；当 $c > 1$ 时，算法允许返回一个足够接近最优答案的点。在高维空间中，精确最近邻通常很难高效解决，因此近似最近邻成为更实际的研究对象。

1.2 LSH 框架与复杂度指数

实际算法通常使用近邻问题的判定版本：在已知数据库中存在点与查询点距离至多为 r 的条件下，返回一个距离至多为 cr 的点。Indyk 和 Motwani 提出的局部敏感哈希 (Locality Sensitive Hashing, LSH) 通过随机哈希使近点更容易碰撞、远点更难碰撞，从而只检查少量候选点 [2]。若近点碰撞概率至少为 p 、远点碰撞概率至多为 q ，则

$$\rho = \frac{\log(1/p)}{\log(1/q)}$$

控制查询复杂度中的指数：查询通常需要约 n^ρ 次距离计算，空间中则出现约 $n^{1+\rho}$ 的项。因此，构造问题是尽量减小 ρ ，而下界问题则要回答：在标准 LSH 模型内， ρ 究竟还能小到什么程度？

1.3 本文评述的问题

本文评述 Motwani、Naor 和 Panigrahy 的 *Lower Bounds on Locality Sensitive Hashing* [1]。论文不提出新的哈希构造，而是首次对整个标准 LSH 模型给出统一的非平凡下界，将“尚未找到更好的算法”推进为“任何满足该模型定义的算法都受到共同限制”。

2 主要定理与贡献

2.1 正式定义

设 (X, d_X) 是一个度量空间。随机哈希函数族 $H : X \rightarrow \mathbb{N}$ 称为 (r, R, p, q) -sensitive，如果对任意 $x, y \in X$ ，有

$$d_X(x, y) \leq r \Rightarrow \Pr_H[H(x) = H(y)] \geq p,$$

并且

$$d_X(x, y) > R \Rightarrow \Pr_H[H(x) = H(y)] \leq q.$$

在近似最近邻问题中通常令 $R = cr$ ，并用

$$\rho = \frac{\log(1/p)}{\log(1/q)}$$

衡量 LSH 的效率。上式中的 ρ 只衡量一个给定哈希族的质量。为了描述度量空间 (X, d_X) 上所有合法哈希族能够达到的最佳指数，进一步定义

$$\rho_X(c) = \sup_{r>0} \inf \left\{ \frac{\log(1/p)}{\log(1/q)} : \begin{array}{l} 0 < p, q < 1, \text{ 且 } X \text{ 上存在一个} \\ (r, cr, p, q)\text{-sensitive 哈希族} \end{array} \right\}.$$

对于高维 ℓ_s 空间，再定义其渐近最佳指数为

$$\rho_s(c) = \limsup_{d \rightarrow \infty} \rho_{\ell_s^d}(c).$$

因此， ρ 是单个哈希族的性能参数，而 $\rho_X(c)$ 和 $\rho_s(c)$ 分别表示在给定空间上对所有合法哈希族优化后的最佳指数，以及该指数在维数趋于无穷时的渐近值。这里 p 越大，说明近点越容易被放到同一个桶中； q 越小，说明远点越不容易误碰撞。因此，一个好的 LSH 需要同时做到“近点高碰撞”和“远点低碰撞”。本文的技术正是围绕这两个要求之间的矛盾展开。

2.2 主定理及适用范围

论文的主定理指出，对任意 $s > 0$ 和 $c > 1$,

$$\rho_s(c) \geq \frac{e^{1/c^s} - 1}{e^{1/c^s} + 1} \geq \frac{0.462}{c^s}.$$

特别地， ℓ_1 与 ℓ_2 空间分别得到 $\Omega(1/c)$ 和 $\Omega(1/c^2)$ 下界。该结论约束的是数据无关的标准 LSH 哈希族，而不是所有近似最近邻数据结构；它也不直接排除数据依赖哈希、图搜索或其他更强模型中的改进。论文的贡献在于首次从 LSH 定义本身推出统一下界，并建立了一套后来可继续加强的 Hamming 立方体分析方法。

3 证明总体思路

3.1 转化到 Hamming 立方体

论文没有直接分析整个高维 ℓ_s^d 空间，而是先分析它的一个特殊子集：

$$\{0, 1\}^d.$$

这个集合是 Hamming 立方体。在该集合上，两个点之间的 ℓ_1 距离等于它们不同坐标的个数。

选择 Hamming 立方体的好处是，它既足够简单，又保留了高维空间的核心困难。立方体中每个点都是一个 0-1 向量，距离就是不同坐标的数量；同时，从一个点出发随机翻转坐标，就得到一个非常自然的随机游走过程。论文正是利用这个随机游走来刻画“从一个点移动到附近点”时哈希值是否仍然相同。

3.2 随机桶与随机游走

第一层是哈希桶分析。固定一个点 x ，并从哈希族 $\mathcal{H}$ 中随机抽取 H ，定义随机桶

$$A_H(x) = H^{-1}(H(x)).$$

这个集合就是 x 在随机哈希函数 H 下所在的桶。远点低碰撞条件说明：如果一个点离 x 很远，那么对 H 的随机性取概率，它落入 $A_H(x)$ 的概率至多是 q 。因此，这一条件限制的是随机桶大小的期望，而不是每一个确定哈希函数所产生的桶大小。

第二层是随机游走分析。论文考虑从点 x 出发，在 Hamming 立方体上随机走 r 步。由于每一步只翻转一个坐标，终点与起点的 Hamming 距离不会超过 r 。先对随机哈希函数使用近点碰撞条件，再对随机游走终点取平均，可知终点以至少 p 的联合概率落入随机桶 $A_H(x)$ 。

3.3 小集合扩散与核心矛盾

第三层是小集合扩散性质。Hamming 立方体上的随机游走会扩散：如果集合 B 很小，那么从 B 中出发的随机游走很难在若干步之后仍然停留在 B 中。这与 LSH 要求的近点高碰撞形成冲突。论文通过傅里叶分析给出这一随机游走概率的上界，并把它与哈希桶大小的上界结合，得到核心不等式

$$p \leq \left(q + \exp \left(-\frac{1}{d} \left(\frac{d}{2} - R \right)^2 \right) \right)^{\frac{e^{2r/d} - 1}{e^{2r/d} + 1}}.$$

这个不等式说明，只要远点碰撞概率 q 很小，近点碰撞概率 p 也会被迫受到限制。最后再把 Hamming 立方体看作 ℓ_s^d 的子集，就可以把该下界推广到高维 ℓ_s 空间。

证明的核心冲突可以概括为

远点低碰撞要求桶不能太大 + 小桶难以困住随机游走 $\Rightarrow$ 近点碰撞概率存在上限。

4 关键技术细节

4.1 第一步：限制哈希桶大小

固定一个点 $x \in \{0,1\}^d$ ，并从哈希族 $\mathcal{H}$ 中随机抽取哈希函数 H ，定义随机桶

$$A_H(x) = H^{-1}(H(x)).$$

集合 $A_H(x)$ 是与 x 哈希到同一个值的所有点。注意，LSH 的碰撞概率是对 $H \sim \mathcal{H}$ 而言的；因此，远点条件控制的是 $|A_H(x)|$ 对随机哈希函数的期望，而不是某个固定 H 的桶大小。

为了估计桶的大小，可以把所有点 $u \in \{0,1\}^d$ 分成两类。第一类是距离 x 不超过 R 的点，它们的数量最多是 Hamming 球的大小

$$\sum_{k=0}^{\lfloor R \rfloor} \binom{d}{k}.$$

对这些点，碰撞概率最多只能粗略地用 1 上界。第二类是距离 x 大于 R 的点。由 LSH 的远点条件，它们与 x 落入同一桶的概率至多是 q 。对所有 u 的碰撞指示变量求和，得到

$$\mathbb{E}_{H \sim \mathcal{H}} |A_H(x)| = \sum_{u \in \{0,1\}^d} \Pr_{H \sim \mathcal{H}} [H(u) = H(x)] \leq \sum_{k=0}^{\lfloor R \rfloor} \binom{d}{k} + q \sum_{k=\lfloor R \rfloor+1}^d \binom{d}{k}.$$

把它除以整个立方体大小 2^d ，就得到桶的平均密度上界。进一步利用 Hamming 球体积估计，当 $R < d/2$ 时，

$$\mathbb{E}_{H \sim \mathcal{H}} \frac{|A_H(x)|}{2^d} \leq q + \exp \left(-\frac{1}{d} \left(\frac{d}{2} - R \right)^2 \right).$$

这里第一项 q 来自远点碰撞概率，第二项来自半径为 R 的 Hamming 球本身在整个立方体中所占的比例。

4.2 第二步：用随机游走连接近点碰撞

在 Hamming 立方体上，从点 x 出发随机翻转一个坐标，重复 r 次，得到随机点 $W_r(x)$ 。由于每一步只改变一个坐标，所以

$$\|x - W_r(x)\|_1 \leq r.$$

因此，对随机游走产生的每一个终点 $y = W_r(x)$ ，近点条件都给出 $\Pr_{H \sim \mathcal{H}}[H(y) = H(x)] \geq p$ 。再对游走终点取平均，得

$$\Pr_{H \sim \mathcal{H}, W_r}[H(W_r(x)) = H(x)] \geq p.$$

这里的概率同时包含两种相互独立的随机性： H 从 $\mathcal{H}$ 中随机抽取， $W_r(x)$ 是随机游走的终点。对任意固定的 H ，碰撞事件等价于 $W_r(x) \in A_H(x)$ ；但 LSH 定义保证的是上述联合概率的下界，并不保证对每个固定的 H ，随机游走都以至少 p 的概率留在桶中。

4.3 第三步：用小集合扩散性质给出上界

Hamming 立方体上的随机游走具有扩散性：如果集合 B 不够大，随机游走从 B 中出发后仍留在 B 中的概率不会太高。论文用 Fourier 分析和 Bonami-Beckner 不等式证明了如下随机游走引理：对任意非空集合 $B \subseteq \{0, 1\}^d$ ，如果 Q_B 表示从 B 中均匀随机选点并走 r 步后的终点，则

$$\Pr[Q_B \in B] \leq \left(\frac{|B|}{2^d} \right)^\alpha, \quad \alpha = \frac{e^{2r/d} - 1}{e^{2r/d} + 1}.$$

这个引理的含义是：桶的相对密度越小，随机游走留在桶中的概率越小。

这里 Fourier 分析的作用，是把“随机游走是否留在集合中”这个组合问题转化为对函数频率成分的估计。具体地说，对集合 B 考虑它的示性函数 $\mathbf{1}_B$ 。在 Hamming 立方体上，任何函数都可以用 Walsh 函数展开：

$$\mathbf{1}_B = \sum_{S \subseteq \{1, \dots, d\}} \widehat{\mathbf{1}_B}(S) W_S.$$

这里 S 可以理解为一组坐标， W_S 描述这些坐标上的奇偶性， $\widehat{\mathbf{1}_B}(S)$ 则表示集合 B 在这种“频率模式”上的权重。

随机游走矩阵 P 对 Walsh 函数的作用非常简单：

$$PW_S = \left(1 - \frac{2|S|}{d} \right) W_S.$$

也就是说，Walsh 函数正好是随机游走的特征向量。经过 r 步随机游走后，频率 S 对应的权重会乘上

$$\left(1 - \frac{2|S|}{d}\right)^r.$$

不能笼统地说所有 $|S|$ 较大的成分都会被快速削弱，因为特征值

$$\lambda_S = 1 - \frac{2|S|}{d}$$

在 $|S|$ 接近 d 时接近 -1 ，其绝对值并不小。正确的处理需要分两部分。当 $|S| \leq d/2$ 时， $\lambda_S \geq 0$ ，且

$$0 \leq \left(1 - \frac{2|S|}{d}\right)^r \leq \exp\left(-\frac{2r|S|}{d}\right),$$

因此这些非负特征值的贡献随 $|S|$ 增大而指数衰减。当 $|S| > d/2$ 时， $\lambda_S < 0$ ；由于论文要求 r 为奇数， λ_S^r 仍为负数，而其前面的 Fourier 系数平方非负，所以这些项在求上界时可以直接丢弃。这正是该证明要求 r 为奇数的实质原因。

于是，随机游走从 B 出发后仍落在 B 中的概率可以写成 Fourier 系数的加权和：

$$\Pr[Q_B \in B] = \frac{2^d}{|B|} \sum_{S \subseteq \{1, \dots, d\}} \widehat{\mathbf{1}_B}(S)^2 \left(1 - \frac{2|S|}{d}\right)^r.$$

接下来需要控制这个加权和。Bonami-Beckner 不等式提供的正是这种控制：当 B 的密度 $|B|/2^d$ 很小时，它的 Fourier 系数不可能让上式过大。换句话说，小集合不能在随机游走下保持太强的稳定性。这一步最终推出

$$\Pr[Q_B \in B] \leq \left(\frac{|B|}{2^d}\right)^{\frac{e^{2r/d}-1}{e^{2r/d}+1}}.$$

4.4 第四步：用 Jensen 不等式闭合上下界

令 x 在 $\{0,1\}^d$ 上均匀分布，并与 H 、随机游走相互独立。条件于固定的 H 和 $H(x) = k$ ，起点 x 在非空桶 $H^{-1}(k)$ 中均匀分布，因而可以对每个桶应用上述随机游走引理。记

$$\alpha = \frac{e^{2r/d} - 1}{e^{2r/d} + 1},$$

则近点碰撞条件和随机游走引理共同给出

$$p \leq \mathbb{E}_H \mathbb{E}_x \left(\frac{|A_H(x)|}{2^d} \right)^\alpha.$$

由于 $0 < \alpha < 1$ ，函数 t^α 为凹函数。Jensen 不等式以及第一步的随机桶密度上界说明

$$\mathbb{E}_H \mathbb{E}_x \left(\frac{|A_H(x)|}{2^d} \right)^\alpha \leq \left(\mathbb{E}_H \mathbb{E}_x \frac{|A_H(x)|}{2^d} \right)^\alpha \leq \left(q + \exp\left(-\frac{(d/2 - R)^2}{d}\right) \right)^\alpha.$$

这就严格闭合了同一碰撞事件的下界与上界，并得到论文的核心命题。

4.5 第五步：从 Hamming 立方体推广到 ℓ_s 空间

由于 $\{0,1\}^d$ 可以看作 ℓ_s^d 的子集，并且在 0-1 向量上距离满足

$$\|x - y\|_s = \|x - y\|_1^{1/s},$$

Hamming 距离上的下界可以转化为 ℓ_s 空间中的下界。最终得到：

$$\rho_s(c) \geq \frac{e^{1/c^s} - 1}{e^{1/c^s} + 1} \geq \frac{0.462}{c^s}.$$

原因是，在 0-1 向量上， ℓ_s 距离等于 Hamming 距离的 $1/s$ 次方。如果在 Hamming 距离中远近阈值的比值是 c^s ，那么在 ℓ_s 距离中对应的比值就是 c 。因此，Hamming 立方体上的下界可以转化为 ℓ_s 空间中的下界。参数选择还需要保证 Hamming 球体积估计中的误差项消失，因此不能只写成 $R \approx d/2$ ，更不能直接取 $R = d/2$ 。一个具体选择是：对于充分大的 d ，取 r_d 为不超过

$$\frac{1}{c^s} \left(\frac{d}{2} - \sqrt{d \log d} \right)$$

的最大奇数，并令 $R_d = c^s r_d$ 。于是

$$R_d = \frac{d}{2} - \sqrt{d \log d} + O(1) = \frac{d}{2} - \Theta(\sqrt{d \log d}), \quad r_d = \frac{R_d}{c^s}.$$

这个选择同时保证 $R_d < d/2$ 、 r_d 为奇数，且

$$\exp \left(-\frac{(d/2 - R_d)^2}{d} \right) = d^{-1+o(1)} \rightarrow 0.$$

另一方面，

$$\frac{2r_d}{d} \rightarrow \frac{1}{c^s},$$

所以随机游走引理中的指数满足

$$\frac{e^{2r_d/d} - 1}{e^{2r_d/d} + 1} \rightarrow \frac{e^{1/c^s} - 1}{e^{1/c^s} + 1}.$$

令 $d \rightarrow \infty$ 后，误差项消失，就得到论文的主定理。

5 与已有及后续工作的比较

5.1 已有上界与本文下界

在本文之前，Indyk 和 Motwani 的构造在 ℓ_1 中达到

$$\rho_1(c) \leq \frac{1}{c}.$$

Datar 等人的 p -稳定分布方法进一步处理了 ℓ_s 空间 [3]，Andoni 和 Indyk 则在 ℓ_2 中得到 $\rho_2(c) \leq 1/c^2$ [4]。这些结果是构造上界；Motwani、Naor 和 Panigrahy 首次给出可与之比较的统一下界。在 ℓ_1 中，本文证明

$$\rho_1(c) \geq \frac{e^{1/c} - 1}{e^{1/c} + 1} \sim \frac{1}{2c} \quad (c \rightarrow \infty).$$

这把差距缩小到常数因子，但并未得到标准数据无关 LSH 的最终紧界。

5.2 O'Donnell–Wu–Zhou 紧下界

O'Donnell、Wu 和 Zhou 后来利用布尔函数噪声稳定性的对数凸性，把 Hamming 空间中的下界提高为

$$\rho \geq \frac{1}{c} - o_d(1)$$

[5]。在 $q \geq 2^{-o(d)}$ （包括固定 q ）的通常范围内，该结果与 $1/c$ 上界匹配，并推出一般 ℓ_s 空间的 $1/c^s - o_d(1)$ 下界，特别是 Euclidean 空间中的紧 $1/c^2$ 下界。因此，本文应评价为开创并奠定了标准 LSH 下界方法，而不是给出了该模型的最终紧常数。

5.3 数据依赖哈希

另一条路线是数据依赖哈希。Andoni 和 Razenshteyn 构造了 Hamming 空间中

$$\rho = \frac{1}{2c-1} + o(1)$$

的方案，Euclidean 空间中的相应指数为 $1/(2c^2-1)$ [6]。他们又在限制哈希函数表示复杂度的简洁模型中证明匹配下界；例如 ℓ_1 中有

$$\rho \geq \frac{1}{2c-1} - o(1)$$

[7]。这说明改变模型可以严格优于数据无关 LSH，但新模型也有自己的紧边界。

6 评价、局限与总结

6.1 贡献与方法价值

本文最重要的贡献有两点。第一，它不再逐个分析具体构造，而是直接从“近点高碰撞、远点低碰撞”的定义推出整个标准 LSH 模型的下界。第二，它把算法问题转化为 Hamming 立方体上的小集合扩散问题，以随机桶、随机游走、Fourier 展开和 Bonami–Beckner 不等式形成了一条可复用的证明路线。这种转化既给出定量结论，也解释了下界产生的原因。

6.2 适用范围与局限

论文也有明确局限。其结论只约束数据无关的标准 LSH，并不是所有近似最近邻数据结构的下界；它对数据依赖哈希、图方法及其他计算模型不直接适用。此外，本文在 ℓ_1 中得到的渐近常数约为 $1/2$ ，与已有 $1/c$ 上界仍有常数差距，后来才由 O'Donnell–Wu–Zhou 闭合。最后，主定理是高维渐近结论，不能直接当作有限维实际系统的精确性能预测。

6.3 总结

总体而言，Motwani、Naor 和 Panigrahy 的论文首次证明高维 ℓ_s 空间中的标准 LSH 必须满足

$$\rho_s(c) \geq \frac{e^{1/c^s} - 1}{e^{1/c^s} + 1} = \Omega(1/c^s).$$

它的持久价值不在于最终常数，而在于揭示了随机桶大小与随机游走稳定性之间的结构性矛盾，并为后续紧下界奠定了方法基础。

参考文献

- [1] R. Motwani, A. Naor, and R. Panigrahy. Lower Bounds on Locality Sensitive Hashing. *Proceedings of the Twenty-second Annual Symposium on Computational Geometry*, 2006.
- [2] P. Indyk and R. Motwani. Approximate Nearest Neighbors: Towards Removing the Curse of Dimensionality. *Proceedings of STOC*, 1998.
- [3] M. Datar, N. Immorlica, P. Indyk, and V. S. Mirrokni. Locality-Sensitive Hashing Scheme Based on p -Stable Distributions. *Proceedings of the Twentieth Annual Symposium on Computational Geometry*, 2004.
- [4] A. Andoni and P. Indyk. Faster Algorithms for High-Dimensional Nearest Neighbor Search. Manuscript, 2005.
- [5] R. O’Donnell, Y. Wu, and Y. Zhou. Optimal Lower Bounds for Locality-Sensitive Hashing (Except When q Is Tiny). *Proceedings of ITCS*, 2011.
- [6] A. Andoni and I. Razenshteyn. Optimal Data-Dependent Hashing for Approximate Near Neighbors. *Proceedings of STOC*, 2015.
- [7] A. Andoni and I. Razenshteyn. Tight Lower Bounds for Data-Dependent Locality-Sensitive Hashing. *Proceedings of the 32nd International Symposium on Computational Geometry*, 2016.