

Lower Bounds on Locality Sensitive Hashing Review

241880622 蒲今

2026 年 7 月 12 日

目录

1 论文概述	2
2 该论文解决了什么问题	2
3 为什么这个问题重要	3
4 相关研究	3
5 论文提出了什么技术	4
6 技术背后的直觉	5
7 技术的非凡之处与好处	6
8 技术是如何实现的	7
9 如何证明技术的正确性	9
10 如何证明技术的优越性	10
11 总结	11

1 论文概述

本文 review 的论文是 Motwani、Naor 和 Panigrahy 在 SoCG 2006 发表的 *Lower Bounds on Locality Sensitive Hashing*。这篇论文研究局部敏感哈希 (Locality Sensitive Hashing, LSH) 在高维近似最近邻问题中的理论下界。LSH 的基本思想是：让距离近的点更容易哈希到同一个桶，让距离远的点不容易哈希到同一个桶。它是处理高维近似最近邻搜索的经典方法。

这篇论文的主要贡献不是提出新的 LSH 构造，而是证明 LSH 本身存在性能极限。作者用参数

$$\rho = \frac{\log(1/p)}{\log(1/q)}$$

刻画 LSH 的效率，其中 p 是近点碰撞概率的下界， q 是远点碰撞概率的上界。 ρ 越小，对应的查询复杂度越低。论文证明，在高维 ℓ_s 空间中，任意 LSH 方法都必须满足

$$\rho_s(c) \geq \frac{e^{1/c^s} - 1}{e^{1/c^s} + 1} \geq \frac{0.462}{c^s}.$$

也就是说，LSH 的复杂度指数不可能低于 $\Omega(1/c^s)$ 。这个下界与已有 LSH 上界在量级上基本匹配，说明已有算法在 LSH 模型内已经接近最优。

论文的证明从 Hamming 立方体 $\{0, 1\}^d$ 入手。作者把哈希碰撞理解为点落入同一个哈希桶：远点低碰撞说明桶不能太大，近点高碰撞又要求随机游走后的近邻点仍有较大概率留在同一桶中。由于 Hamming 立方体上的随机游走会快速扩散，小桶很难同时满足这两个要求。这个冲突最终给出了 ρ 的下界。

2 该论文解决了什么问题

近似最近邻问题要求：给定一个预处理后的点集 P ，对于查询点 q ，快速找到一个点 $x \in P$ ，使得

$$d(q, x) \leq c \cdot \min_{y \in P} d(q, y),$$

其中 $c > 1$ 是近似因子。当 $c = 1$ 时是精确最近邻；当 $c > 1$ 时，算法允许返回一个足够接近最优答案的点。在高维空间中，精确最近邻通常很难高效解决，因此近似最近邻成为更实际的研究对象。

LSH 是近似最近邻的经典方法，但它的能力边界并不显然。根据 Indyk 和 Motwani 的 LSH 框架，如果存在好的 (r, cr, p, q) -sensitive 哈希族，就可以得到查询时间大约为 n^ρ 的算法，其中

$$\rho = \frac{\log(1/p)}{\log(1/q)}$$

由近点碰撞概率 p 和远点碰撞概率 q 决定。因此， ρ 越小，LSH 查询越快。已有构造说明在 ℓ_1 空间中可以达到大约 $1/c$ 的量级，在 ℓ_2 空间中可以达到大约 $1/c^2$ 的量级；但这些只是上界，只说明“可以做到这么好”，并不说明“不能更好”。

这篇论文解决的正是这个最优性问题：在高维 ℓ_s 空间中，是否存在某种未知的 LSH 哈希族，能让 ρ 远小于已有构造？论文的回答是否定的。它证明所有满足 LSH 定义的哈希方法都受

到统一限制：在该模型内， ρ 不能低于 $\Omega(1/c^s)$ 。因此，本文把“是否还有更好的 LSH”这个问题，从对具体算法的比较变成了对整个 LSH 模型的下界证明。

3 为什么这个问题重要

高维最近邻搜索是许多应用中的基础问题，例如相似文档检索、图像检索、推荐系统和机器学习中的向量搜索。在这些场景中，一个对象通常被表示成高维向量，系统需要在大量数据中快速找到与查询对象最相似的点。如果逐一比较所有点，查询代价会随数据规模线性增长，难以适应大规模数据。

这个问题在高维空间中尤其困难。许多低维几何数据结构在维度升高后效果迅速变差，这就是所谓的维数灾难。因此，近似最近邻算法变得非常重要，而 LSH 是其中最具有代表性的通用方法之一。

本文的重要性在于，它说明 LSH 的瓶颈不是某个具体构造的缺陷，而是模型本身的限制。在标准 LSH 框架中，查询时间大致包含 n^ρ 量级的距离计算，空间复杂度也会出现 $n^{1+\rho}$ 量级的项；因此 ρ 的下界直接限制了 LSH 能带来的加速幅度。本文证明的 $\Omega(1/c^s)$ 下界与已有上界基本匹配，这说明在同一 LSH 模型内，继续寻找数量级更好的哈希族不会有太大空间。

这种结论对后续研究也有指导意义：如果想显著突破已有性能，就可能需要使用更强的模型、数据依赖的方法，或者转向 LSH 之外的近似最近邻数据结构。

4 相关研究

4.1 论文中提到的相关研究

这篇论文最直接的背景是 Indyk 和 Motwani 在 1998 年提出的 LSH 框架 [2]。这个框架把近似最近邻问题转化为构造合适的随机哈希族：如果近点以较高概率碰撞、远点以较低概率碰撞，就可以通过多次哈希和查桶来减少需要检查的候选点数量。因此，LSH 的核心不再只是设计一个数据结构，而是设计具有良好碰撞概率的哈希分布。

在这条研究线上，已有工作给出了若干重要上界。Indyk 和 Motwani 的结果说明，在 ℓ_1 空间中可以达到 $\rho_1(c) \leq 1/c$ 。Datar、Immorlica、Indyk 和 Mirrokni 后来提出了基于 p -稳定分布的 LSH 方法 [3]，进一步系统地处理 ℓ_s 空间中的近似最近邻问题。Andoni 和 Indyk 的结果则给出了 ℓ_2 空间中 $\rho_2(c) \leq 1/c^2$ 的更强上界 [4]。本文正是在这些上界之后提出问题：这些上界只是说明 LSH 可以做到这么好，但它们是否已经接近最优？

本文的贡献就是给出与这些上界基本匹配的下界。尤其对于 ℓ_1 空间，已有上界是 $1/c$ ，本文证明下界为常数倍的 $1/c$ ；对于 ℓ_2 空间，已有上界是 $1/c^2$ ，本文也证明了同量级的下界。因此，这篇论文不是替代前人的 LSH 构造，而是解释为什么这些构造在渐近量级上已经很难被显著改进。

4.2 论文未详细提到但相关的研究

最近邻搜索本身有很长的研究历史，LSH 只是其中一种路线。另一类方法试图用几何数据结构直接划分空间，例如 Voronoi 图、树结构或空间分割方法。这些方法在低维空间中很有用，但在高维空间中常常受到维数灾难影响。因此，高维近似最近邻研究通常更关注随机化、近似化和高维概率结构。

还有一些相关方向研究更强的计算模型下界，例如 cell-probe 模型中的数据结构下界。这类结果关心的是：即使允许非常灵活的数据结构，一个问题仍然需要多少空间或查询时间。本文的下界与此不同，它不是针对所有可能的数据结构，而是专门针对 LSH 这种“近点高碰撞、远点低碰撞”的方法。因此，本文结论的适用范围更窄，但也更精确地刻画了 LSH 框架本身的能力边界。

4.3 论文发表后的后续研究

本文发表之后，近似最近邻和 LSH 仍然是活跃方向。一个重要发展是数据依赖的哈希方法：传统 LSH 的哈希族通常与具体数据集无关，而数据依赖方法允许根据输入数据选择或学习哈希结构，因此有可能突破某些数据无关 LSH 的限制。

从应用角度看，近似最近邻搜索也成为现代向量检索和向量数据库的重要基础。实际系统中常常结合哈希、图搜索、量化和聚类等多种技术。这说明本文的下界并不意味着近似最近邻问题无法继续改进，而是提醒我们：如果仍然限制在标准 LSH 模型内，已有结果已经接近理论边界；若要得到更强性能，往往需要改变模型假设或使用其他类型的数据结构。

5 论文提出了什么技术

5.1 LSH 的基本形式

设 (X, d_X) 是一个度量空间。随机哈希函数族 $H : X \rightarrow \mathbb{N}$ 称为 (r, R, p, q) -sensitive，如果对任意 $x, y \in X$ ，有

$$d_X(x, y) \leq r \Rightarrow \Pr_H[H(x) = H(y)] \geq p,$$

并且

$$d_X(x, y) > R \Rightarrow \Pr_H[H(x) = H(y)] \leq q.$$

在近似最近邻问题中通常令 $R = cr$ ，并用

$$\rho = \frac{\log(1/p)}{\log(1/q)}$$

衡量 LSH 的效率。这里 p 越大，说明近点越容易被放到同一个桶中； q 越小，说明远点越不容易误碰撞。因此，一个好的 LSH 需要同时做到“近点高碰撞”和“远点低碰撞”。本文的技术正是围绕这两个要求之间的矛盾展开。

5.2 论文的核心技术路线

论文没有直接分析整个高维 ℓ_s^d 空间，而是先分析它的一个特殊子集：

$$\{0, 1\}^d.$$

这个集合是 Hamming 立方体。在该集合上，两个点之间的 ℓ_1 距离等于它们不同坐标的个数。

选择 Hamming 立方体的好处是，它既足够简单，又保留了高维空间的核心困难。立方体中每个点都是一个 0-1 向量，距离就是不同坐标的数量；同时，从一个点出发随机翻转坐标，就得到一个非常自然的随机游走过程。论文正是利用这个随机游走来刻画“从一个点移动到附近点”时哈希值是否仍然相同。

更具体地说，论文把证明分成三层。

第一层是哈希桶分析。固定一个点 x ，所有与 x 哈希到同一个值的点构成集合

$$A = H^{-1}(H(x)).$$

这个集合就是 x 所在的哈希桶。远点低碰撞条件说明：如果一个点离 x 很远，它落入同一桶的概率至多是 q 。因此，哈希桶不能在整个 Hamming 立方体中占据太大比例；否则远点之间同桶的概率会过高。

第二层是随机游走分析。论文考虑从桶中的点出发，在 Hamming 立方体上随机走 r 步。由于每一步只翻转一个坐标，终点与起点的 Hamming 距离不会超过 r 。如果 H 真的是一个好的 LSH，那么这些近点应当有较大概率仍然落在同一个桶中，也就是随机游走应当有较大概率从 A 出发后仍回到 A 。

第三层是小集合扩散性质。Hamming 立方体上的随机游走会扩散：如果集合 A 很小，那么从 A 中出发的随机游走很难在若干步之后仍然停留在 A 中。这与 LSH 要求的近点高碰撞形成冲突。论文通过傅里叶分析给出这一随机游走概率的上界，并把它与哈希桶大小的上界结合，得到核心不等式

$$p \leq \left(q + \exp \left(-\frac{1}{d} \left(\frac{d}{2} - R \right)^2 \right) \right)^{\frac{e^{2r/d-1}}{e^{2r/d+1}}}.$$

这个不等式说明，只要远点碰撞概率 q 很小，近点碰撞概率 p 也会被迫受到限制。最后再把 Hamming 立方体看作 ℓ_s^d 的子集，就可以把该下界推广到高维 ℓ_s 空间。

6 技术背后的直觉

这篇论文的直觉可以从“哈希桶的大小”来理解。一个哈希值对应一个桶，所有被映射到这个值的点都在同一个桶中。LSH 希望近点容易进入同一个桶，远点不容易进入同一个桶。这两个目标本身是有张力的：如果桶很大，它更容易包含近点，但也更容易误包含很多远点；如果桶很小，它能减少远点误碰撞，却很难保证所有近点仍然留在同一个桶中。

远点低碰撞条件首先限制了桶的大小。直观地说，如果一个桶占据了 Hamming 立方体中的很大一部分，那么随机选到的两个同桶点很可能相距较远。这会使远点碰撞概率变大，违背 LSH 对 q 的要求。因此，当 q 很小时，典型的哈希桶不能太大。

但近点高碰撞条件又要求桶不能太“脆弱”。论文用随机游走来表达这一点：从桶中的一个点出发，每一步随机翻转一个坐标。走了 r 步以后，终点与起点的距离仍然不超过 r ，所以它可以看作起点附近的一个点。如果 LSH 希望近点以概率至少 p 碰撞，那么这个随机游走的终点就应该有相当概率仍然落在原来的桶中。

问题在于，Hamming 立方体上的随机游走会迅速扩散。举一个简单例子：如果桶只包含一个点，那么随机游走只要走一步就一定离开这个桶；如果桶只是一小块区域，那么多走几步以后也很容易走到桶外。更一般地说，小集合很难把随机游走“困住”。因此，远点条件迫使桶小，而小桶又无法支持很高的近点碰撞概率。

这就是证明的核心冲突：

远点低碰撞要求桶不能太大 + 小桶难以困住随机游走 $\Rightarrow$ 近点碰撞概率存在上限。

论文的证明就是把这个直觉变成严格不等式。它先用远点碰撞概率 q 上界哈希桶的平均密度，再用随机游走和傅里叶分析说明：桶的密度越小，随机游走留在桶中的概率越低。最后，由于近点碰撞概率 p 不能超过这个留在桶中的概率，就得到 p 的上界，并进一步推出 ρ 的下界。

7 技术的非凡之处与好处

这篇论文最重要的特点是，它没有逐个分析某个具体的 LSH 构造，而是直接从 LSH 的定义出发。只要一个方法满足“近点高碰撞、远点低碰撞”这两个条件，它就会受到论文证明的下界限制。因此，结论不是针对某个算法的缺点，而是针对整个 LSH 模型的能力边界。

这种证明比只分析一个具体算法更强。分析具体算法时，即使证明它不能做得更好，也不能排除别的哈希构造可能更优。而本文证明的是：无论哈希函数如何设计，只要仍然属于标准 LSH 框架，就无法突破同样的量级限制。这正是下界结果的价值所在，它把“我们还没有找到更好的算法”变成了“在这个模型内确实不存在数量级更好的算法”。

另一个巧妙之处是，论文把算法问题转化成了 Hamming 立方体上的几何和概率问题。原本的问题是 LSH 查询复杂度能否继续降低，经过转化后变成了：一个集合既要足够小以避免远点碰撞，又要足够大以留住随机游走，这是否可能？这个转化把抽象的算法性能问题变成了可以用组合、概率和傅里叶分析处理的问题。

这种技术的好处是解释力很强。它不仅告诉我们下界是多少，还解释了下界为什么会出现：LSH 同时追求的两个目标本身存在冲突。远点低碰撞要求哈希桶不能太大，近点高碰撞又要求哈希桶对局部扰动足够稳定。Hamming 立方体上的扩散性质说明，这两个要求不能同时被无限限制地满足。因此，论文的证明不只是形式上推出一个不等式，也给出了理解 LSH 极限的清晰图景。

8 技术是如何实现的

8.1 第一步：限制哈希桶大小

固定一个哈希函数和一个点 $x \in \{0, 1\}^d$ ，令

$$A = H^{-1}(H(x)).$$

集合 A 是与 x 哈希到同一个值的所有点。远点碰撞概率小意味着：如果某些点与 x 距离大于 R ，它们落入同一个桶的概率不能超过 q 。

为了估计桶的大小，可以把所有点 $u \in \{0, 1\}^d$ 分成两类。第一类是距离 x 不超过 R 的点，它们的数量最多是 Hamming 球的大小

$$\sum_{k=0}^{\lfloor R \rfloor} \binom{d}{k}.$$

对这些点，碰撞概率最多只能粗略地用 1 上界。第二类是距离 x 大于 R 的点。由 LSH 的远点条件，它们与 x 落入同一桶的概率至多是 q 。因此有

$$\mathbb{E}|H^{-1}(H(x))| \leq \sum_{k=0}^{\lfloor R \rfloor} \binom{d}{k} + q \sum_{k=\lfloor R \rfloor+1}^d \binom{d}{k}.$$

把它除以整个立方体大小 2^d ，就得到桶的平均密度上界。进一步利用 Hamming 球体积估计，当 $R < d/2$ 时，

$$\mathbb{E} \frac{|H^{-1}(H(x))|}{2^d} \leq q + \exp \left(-\frac{1}{d} \left(\frac{d}{2} - R \right)^2 \right).$$

这里第一项 q 来自远点碰撞概率，第二项来自半径为 R 的 Hamming 球本身在整个立方体中所占的比例。

8.2 第二步：用随机游走连接近点碰撞

在 Hamming 立方体上，从点 x 出发随机翻转一个坐标，重复 r 次，得到随机点 $W_r(x)$ 。由于每一步只改变一个坐标，所以

$$\|x - W_r(x)\|_1 \leq r.$$

因此，LSH 的近点条件给出

$$\Pr[H(W_r(x)) = H(x)] \geq p.$$

如果 x 属于某个哈希桶 B ，那么事件 $H(W_r(x)) = H(x)$ 就等价于随机游走终点仍然落在桶 B 中。于是，近点碰撞概率可以转化为“随机游走从桶中出发后仍留在桶中”的概率。

8.3 第三步：用小集合扩散性质给出上界

Hamming 立方体上的随机游走具有扩散性：如果集合 A 不够大，随机游走从 A 中出发后仍留在 A 中的概率不会太高。论文用 Fourier 分析和 Bonami-Beckner 不等式证明了如下随机

游走引理：对任意非空集合 $B \subseteq \{0, 1\}^d$ ，如果 Q_B 表示从 B 中均匀随机选点并走 r 步后的终点，则

$$\Pr[Q_B \in B] \leq \left(\frac{|B|}{2^d}\right)^\alpha, \quad \alpha = \frac{e^{2r/d} - 1}{e^{2r/d} + 1}.$$

这个引理的含义是：桶的相对密度越小，随机游走留在桶中的概率越小。

这里 Fourier 分析的作用，是把“随机游走是否留在集合中”这个组合问题转化为对函数频率成分的估计。具体地说，对集合 B 考虑它的示性函数 $\mathbf{1}_B$ 。在 Hamming 立方体上，任何函数都可以用 Walsh 函数展开：

$$\mathbf{1}_B = \sum_{S \subseteq \{1, \dots, d\}} \widehat{\mathbf{1}_B}(S) W_S.$$

这里 S 可以理解为一组坐标， W_S 描述这些坐标上的奇偶性， $\widehat{\mathbf{1}_B}(S)$ 则表示集合 B 在这种“频率模式”上的权重。

随机游走矩阵 P 对 Walsh 函数的作用非常简单：

$$PW_S = \left(1 - \frac{2|S|}{d}\right) W_S.$$

也就是说，Walsh 函数正好是随机游走的特征向量。经过 r 步随机游走后，频率 S 对应的权重会乘上

$$\left(1 - \frac{2|S|}{d}\right)^r.$$

高频部分，也就是 $|S|$ 较大的部分，会在随机游走中被快速削弱。这正对应随机游走的“平滑”和“扩散”效果。

于是，随机游走从 B 出发后仍落在 B 中的概率可以写成 Fourier 系数的加权和：

$$\Pr[Q_B \in B] = \frac{2^d}{|B|} \sum_{S \subseteq \{1, \dots, d\}} \widehat{\mathbf{1}_B}(S)^2 \left(1 - \frac{2|S|}{d}\right)^r.$$

接下来需要控制这个加权和。Bonami-Beckner 不等式提供的正是这种控制：当 B 的密度 $|B|/2^d$ 很小时，它的 Fourier 系数不可能让上式过大。换句话说，小集合不能在随机游走下保持太强的稳定性。论文中要求 r 为奇数，也是为了方便处理上式中的特征值：当 $|S| > d/2$ 时， $1 - 2|S|/d$ 为负，奇数次幂仍为负；在做上界时可以直接丢弃这些负项。这一步最终推出

$$\Pr[Q_B \in B] \leq \left(\frac{|B|}{2^d}\right)^{\frac{e^{2r/d} - 1}{e^{2r/d} + 1}}.$$

将这个引理应用到每个哈希桶，再结合第一步得到的桶密度上界，就得到核心命题：

$$p \leq \left(q + \exp\left(-\frac{1}{d}\left(\frac{d}{2} - R\right)^2\right)\right)^{\frac{e^{2r/d} - 1}{e^{2r/d} + 1}}.$$

其中，括号中的 q 来自远点碰撞概率；指数误差项来自 Hamming 球体积估计；外面的幂指数 $\frac{e^{2r/d} - 1}{e^{2r/d} + 1}$ 来自随机游走引理。这个不等式把 LSH 的两个要求连接起来：远点碰撞概率越小，桶越小，进而近点碰撞概率 p 也不能太大。

8.4 第四步：从 Hamming 立方体推广到 ℓ_s 空间

由于 $\{0,1\}^d$ 可以看作 ℓ_s^d 的子集，并且在 0-1 向量上距离满足

$$\|x - y\|_s = \|x - y\|_1^{1/s},$$

Hamming 距离上的下界可以转化为 ℓ_s 空间中的下界。最终得到：

$$\rho_s(c) \geq \frac{e^{1/c^s} - 1}{e^{1/c^s} + 1} \geq \frac{0.462}{c^s}.$$

原因是，在 0-1 向量上， ℓ_s 距离等于 Hamming 距离的 $1/s$ 次方。如果在 Hamming 距离中远近阈值的比值是 c^s ，那么在 ℓ_s 距离中对应的比值就是 c 。因此，Hamming 立方体上的下界可以转化为 ℓ_s 空间中的下界。最后选择合适的参数 $R \approx d/2$ 和 $r \approx R/c^s$ ，并令维度 d 趋于无穷，就得到论文的主定理。

9 如何证明技术的正确性

这项技术的正确性来自一条完整的上下界比较链。证明并没有改变 LSH 的定义，而是把同一个碰撞事件从两个角度进行估计：一方面，近点条件要求碰撞概率至少为 p ；另一方面，桶大小和随机游走扩散性质又给出这个概率的上界。两者合在一起，就能推出 p 不能太大。

首先，哈希桶分析是合法的，因为它只是重新表达碰撞事件。固定哈希函数 H 和点 x ，集合

$$H^{-1}(H(x))$$

正是所有与 x 哈希到同一个值的点。因此，事件 $H(u) = H(x)$ 等价于 u 落入 x 所在的哈希桶。当 u 与 x 的距离大于 R 时，LSH 的远点条件直接给出

$$\Pr[H(u) = H(x)] \leq q.$$

这说明用远点条件估计桶大小没有额外假设，只是在对所有可能的 u 分情况求和。

其次，随机游走确实可以使用近点条件。令 $W_r(x)$ 表示从 x 出发在 Hamming 立方体上走 r 步后的点。因为每一步只翻转一个坐标，所以无论随机过程怎么走，都有

$$\|x - W_r(x)\|_1 \leq r.$$

如果哈希族是 (r, R, p, q) -sensitive，那么由近点条件可知

$$\Pr[H(W_r(x)) = H(x)] \geq p.$$

这一步说明，随机游走终点确实是可以用于检测近点碰撞的对象，而不是任意选出的远点。

接下来，把上述碰撞事件按哈希桶分解。若哈希值为 k 的桶是 $H^{-1}(k)$ ，并且 $x \in H^{-1}(k)$ ，那么事件 $H(W_r(x)) = H(x)$ 等价于

$$W_r(x) \in H^{-1}(k).$$

也就是说，碰撞概率可以看成随机游走从某个桶中出发后仍留在这个桶中的概率。对每个桶使用随机游走引理，得到

$$\Pr[Q_{H^{-1}(k)} \in H^{-1}(k)] \leq \left(\frac{|H^{-1}(k)|}{2^d} \right)^\alpha, \quad \alpha = \frac{e^{2r/d} - 1}{e^{2r/d} + 1}.$$

因此，近点碰撞概率满足

$$p \leq \mathbb{E}_H \mathbb{E}_x \left(\frac{|H^{-1}(H(x))|}{2^d} \right)^\alpha.$$

最后一步是把桶密度的上界代入。由于 $0 < \alpha < 1$ ，函数 t^α 是凹函数，所以 Jensen 不等式给出

$$\mathbb{E}_H \left(\frac{|H^{-1}(H(x))|}{2^d} \right)^\alpha \leq \left(\mathbb{E}_H \frac{|H^{-1}(H(x))|}{2^d} \right)^\alpha.$$

而前面已经证明

$$\mathbb{E}_H \frac{|H^{-1}(H(x))|}{2^d} \leq q + \exp \left(-\frac{(d/2 - R)^2}{d} \right).$$

于是得到

$$p \leq \left(q + \exp \left(-\frac{(d/2 - R)^2}{d} \right) \right)^{\frac{e^{2r/d} - 1}{e^{2r/d} + 1}},$$

这正是论文的核心命题。

从这个命题推出 ℓ_s 空间的结论也没有丢失严谨性。原因是 $\{0, 1\}^d$ 是 ℓ_s^d 的一个子集。如果整个 ℓ_s^d 上存在一个比下界更好的 LSH 哈希族，那么把这个哈希族限制在子集 $\{0, 1\}^d$ 上，就会得到 Hamming 立方体上的一个同样好的哈希族，从而违反刚刚证明的子空间下界。因此，子空间上的困难性可以推出整个空间上的困难性。再利用 0-1 向量上的关系

$$\|x - y\|_s = \|x - y\|_1^{1/s},$$

就得到高维 ℓ_s 空间中的主定理。

10 如何证明技术的优越性

这里的“优越性”不是指论文提出了一个运行更快的新算法，而是指它证明了已有 LSH 方法在理论上已经接近最优。已有工作给出了若干 LSH 上界，而本文给出的下界与这些上界在主要量级上相匹配。因此，它证明的是一种“最优性”：在标准 LSH 模型内，继续寻找数量级更好的哈希族不会有太大空间。

具体来说，对于 ℓ_1 空间，Indyk 和 Motwani 的构造给出

$$\rho_1(c) \leq \frac{1}{c}.$$

本文的结果则推出

$$\rho_1(c) \geq \frac{e^{1/c} - 1}{e^{1/c} + 1} \sim \frac{1}{2c} \quad (c \rightarrow \infty).$$

上下界只差一个常数因子。这说明，在 ℓ_1 空间中，已有 LSH 构造已经不能被数量级地改进。

对于 ℓ_2 空间, Andoni 和 Indyk 的结果给出

$$\rho_2(c) \leq \frac{1}{c^2}.$$

而本文的主定理给出

$$\rho_s(c) = \Omega(1/c^s).$$

取 $s = 2$ 时得到

$$\rho_2(c) = \Omega(1/c^2).$$

因此在 ℓ_2 空间中, 上界和下界达到同一量级, 即

$$\rho_2(c) = \Theta(1/c^2)$$

在 LSH 模型下成立。

这种匹配关系说明, 论文中的证明技术足够强: 它不是给出一个很松的下界, 而是几乎抓住了 LSH 的真实极限。如果下界远低于已有上界, 它只能说明“存在某个限制”, 但无法判断已有算法是否接近最优; 而本文的下界与已有构造同阶, 就能说明 LSH 框架的性能边界已经基本被刻画出来。

这也给后续研究提供了清晰判断标准。如果研究者仍然使用标准 LSH 框架, 那么不应期待把 ρ 降到远小于上述量级; 如果希望显著突破, 就需要改变模型, 例如使用数据依赖方法、更强的数据结构, 或者采用与 LSH 不同的近似最近邻技术。

11 总结

这篇论文研究的是 LSH 在高维近似最近邻问题中的理论极限。它关心的不是如何设计一个新的哈希算法, 而是所有标准 LSH 方法共同受到什么限制。论文证明, 在高维 ℓ_s 空间中, LSH 的复杂度指数 ρ 不可能低于 $\Omega(1/c^s)$ 。这个结果与已有 LSH 构造的上界基本匹配, 因此说明已有算法在该模型内已经接近最优。

论文的核心直觉是, LSH 同时要求“近点容易碰撞”和“远点不容易碰撞”, 但这两个要求之间存在内在冲突。如果哈希桶太大, 就容易让远点也落入同一个桶; 如果哈希桶太小, 又很难保证近点仍然留在同一个桶中。作者把这个直觉放到 Hamming 立方体上, 用随机游走刻画近点关系, 用桶大小刻画远点碰撞限制, 再通过 Fourier 分析和 Bonami-Beckner 不等式证明小集合难以留住随机游走, 从而得到严格下界。

这个证明可信的关键在于, 每一步都直接对应 LSH 定义中的条件: 远点条件限制桶的平均大小, 近点条件给出随机游走留在桶中的概率下界, 而随机游走引理给出同一概率的上界。上下界比较后, 近点碰撞概率 p 被限制住, 进而限制了 ρ 。最后, Hamming 立方体作为 ℓ_s^d 的子集, 使得子空间中的困难性可以推广到整个高维空间。

我认为这篇论文最有价值的地方, 是它展示了算法下界证明的力量。它不仅告诉我们某个具体算法不能再改进, 而是说明一个算法框架本身的能力边界在哪里。对于 LSH 来说, 如果仍然坚持数据无关的标准哈希框架, 就不应期待获得数量级更好的复杂度; 如果希望继续突破, 就

需要考虑数据依赖方法或 LSH 之外的近似最近邻技术。因此，这篇论文既解释了已有算法为什么接近最优，也为后续研究指明了哪些方向可能真正带来新的改进。

参考文献

- [1] R. Motwani, A. Naor, and R. Panigrahy. Lower Bounds on Locality Sensitive Hashing. *Proceedings of the Twenty-second Annual Symposium on Computational Geometry*, 2006.
- [2] P. Indyk and R. Motwani. Approximate Nearest Neighbors: Towards Removing the Curse of Dimensionality. *Proceedings of STOC*, 1998.
- [3] M. Datar, N. Immorlica, P. Indyk, and V. S. Mirrokni. Locality-Sensitive Hashing Scheme Based on p-Stable Distributions. *Proceedings of the Twentieth Annual Symposium on Computational Geometry*, 2004.
- [4] A. Andoni and P. Indyk. Faster Algorithms for High-Dimensional Nearest Neighbor Search. Manuscript, 2005.