

Lower Bounds on Locality Sensitive Hashing Review

241880622 蒲今

2026 年 7 月 9 日

目录

1 论文概述	2
2 该论文解决了什么问题	2
3 为什么这个问题重要	3
4 相关研究	3
5 论文提出了什么技术	4
6 技术背后的直觉	5
7 技术的非凡之处与好处	6
8 技术是如何实现的	6
9 如何证明技术的正确性	7
10 如何证明技术的优越性	8
11 总结	8

1 论文概述

本文 review 的论文是 Motwani、Naor 和 Panigrahy 在 SoCG 2006 发表的 *Lower Bounds on Locality Sensitive Hashing*。这篇论文研究局部敏感哈希 (Locality Sensitive Hashing, LSH) 在高维近似最近邻问题中的理论下界。LSH 的基本思想是：让距离近的点更容易哈希到同一个桶，让距离远的点不容易哈希到同一个桶。它是处理高维近似最近邻搜索的经典方法。

这篇论文的主要贡献不是提出新的 LSH 构造，而是证明 LSH 本身存在性能极限。作者用参数

$$\rho = \frac{\log(1/p)}{\log(1/q)}$$

刻画 LSH 的效率，其中 p 是近点碰撞概率的下界， q 是远点碰撞概率的上界。 ρ 越小，对应的查询复杂度越低。论文证明，在高维 ℓ_s 空间中，任意 LSH 方法都必须满足

$$\rho_s(c) \geq \frac{e^{1/c^s} - 1}{e^{1/c^s} + 1} \geq \frac{0.462}{c^s}.$$

也就是说，LSH 的复杂度指数不可能低于 $\Omega(1/c^s)$ 。这个下界与已有 LSH 上界在量级上基本匹配，说明已有算法在 LSH 模型内已经接近最优。

论文的证明从 Hamming 立方体 $\{0, 1\}^d$ 入手。作者把哈希碰撞理解为点落入同一个哈希桶：远点低碰撞说明桶不能太大，近点高碰撞又要求随机游走后的近邻点仍有较大概率留在同一桶中。由于 Hamming 立方体上的随机游走会快速扩散，小桶很难同时满足这两个要求。这个冲突最终给出了 ρ 的下界。

2 该论文解决了什么问题

近似最近邻问题要求：给定一个预处理后的点集 P ，对于查询点 q ，快速找到一个点 $x \in P$ ，使得

$$d(q, x) \leq c \cdot \min_{y \in P} d(q, y),$$

其中 $c > 1$ 是近似因子。当 $c = 1$ 时是精确最近邻；当 $c > 1$ 时，算法允许返回一个足够接近最优答案的点。在高维空间中，精确最近邻通常很难高效解决，因此近似最近邻成为更实际的研究对象。

LSH 是近似最近邻的经典方法，但它的能力边界并不显然。根据 Indyk 和 Motwani 的 LSH 框架，如果存在好的 (r, cr, p, q) -sensitive 哈希族，就可以得到查询时间大约为 n^ρ 的算法，其中

$$\rho = \frac{\log(1/p)}{\log(1/q)}$$

由近点碰撞概率 p 和远点碰撞概率 q 决定。因此， ρ 越小，LSH 查询越快。已有构造说明在 ℓ_1 空间中可以达到大约 $1/c$ 的量级，在 ℓ_2 空间中可以达到大约 $1/c^2$ 的量级；但这些只是上界，只说明“可以做到这么好”，并不说明“不能更好”。

这篇论文解决的正是这个最优性问题：在高维 ℓ_s 空间中，是否存在某种未知的 LSH 哈希族，能让 ρ 远小于已有构造？论文的回答是否定的。它证明所有满足 LSH 定义的哈希方法都受

到统一限制：在该模型内， ρ 不能低于 $\Omega(1/c^s)$ 。因此，本文把“是否还有更好的 LSH”这个问题，从对具体算法的比较变成了对整个 LSH 模型的下界证明。

3 为什么这个问题重要

高维最近邻搜索是许多应用中的基础问题，例如相似文档检索、图像检索、推荐系统和机器学习中的向量搜索。在这些场景中，一个对象通常被表示成高维向量，系统需要在大量数据中快速找到与查询对象最相似的点。如果逐一比较所有点，查询代价会随数据规模线性增长，难以适应大规模数据。

这个问题在高维空间中尤其困难。许多低维几何数据结构在维度升高后效果迅速变差，这就是所谓的维数灾难。因此，近似最近邻算法变得非常重要，而 LSH 是其中最具有代表性的通用方法之一。

本文的重要性在于，它说明 LSH 的瓶颈不是某个具体构造的缺陷，而是模型本身的限制。在标准 LSH 框架中，查询时间大致包含 n^ρ 量级的距离计算，空间复杂度也会出现 $n^{1+\rho}$ 量级的项；因此 ρ 的下界直接限制了 LSH 能带来的加速幅度。本文证明的 $\Omega(1/c^s)$ 下界与已有上界基本匹配，这说明在同一 LSH 模型内，继续寻找数量级更好的哈希族不会有太大空间。

这种结论对后续研究也有指导意义：如果想显著突破已有性能，就可能需要使用更强的模型、数据依赖的方法，或者转向 LSH 之外的近似最近邻数据结构。

4 相关研究

4.1 论文中提到的相关研究

这篇论文最直接的背景是 Indyk 和 Motwani 在 1998 年提出的 LSH 框架 [2]。这个框架把近似最近邻问题转化为构造合适的随机哈希族：如果近点以较高概率碰撞、远点以较低概率碰撞，就可以通过多次哈希和查桶来减少需要检查的候选点数量。因此，LSH 的核心不再只是设计一个数据结构，而是设计具有良好碰撞概率的哈希分布。

在这条研究线上，已有工作给出了若干重要上界。Indyk 和 Motwani 的结果说明，在 ℓ_1 空间中可以达到 $\rho_1(c) \leq 1/c$ 。Datar、Immorlica、Indyk 和 Mirrokni 后来提出了基于 p -稳定分布的 LSH 方法 [3]，进一步系统地处理 ℓ_s 空间中的近似最近邻问题。Andoni 和 Indyk 的结果则给出了 ℓ_2 空间中 $\rho_2(c) \leq 1/c^2$ 的更强上界 [4]。本文正是在这些上界之后提出问题：这些上界只是说明 LSH 可以做到这么好，但它们是否已经接近最优？

本文的贡献就是给出与这些上界基本匹配的下界。尤其对于 ℓ_1 空间，已有上界是 $1/c$ ，本文证明下界为常数倍的 $1/c$ ；对于 ℓ_2 空间，已有上界是 $1/c^2$ ，本文也证明了同量级的下界。因此，这篇论文不是替代前人的 LSH 构造，而是解释为什么这些构造在渐近量级上已经很难被显著改进。

4.2 论文未详细提到但相关的研究

最近邻搜索本身有很长的研究历史，LSH 只是其中一种路线。另一类方法试图用几何数据结构直接划分空间，例如 Voronoi 图、树结构或空间分割方法。这些方法在低维空间中很有用，但在高维空间中常常受到维数灾难影响。因此，高维近似最近邻研究通常更关注随机化、近似化和高维概率结构。

还有一些相关方向研究更强的计算模型下界，例如 cell-probe 模型中的数据结构下界。这类结果关心的是：即使允许非常灵活的数据结构，一个问题仍然需要多少空间或查询时间。本文的下界与此不同，它不是针对所有可能的数据结构，而是专门针对 LSH 这种“近点高碰撞、远点低碰撞”的方法。因此，本文结论的适用范围更窄，但也更精确地刻画了 LSH 框架本身的能力边界。

4.3 论文发表后的后续研究

本文发表之后，近似最近邻和 LSH 仍然是活跃方向。一个重要发展是数据依赖的哈希方法：传统 LSH 的哈希族通常与具体数据集无关，而数据依赖方法允许根据输入数据选择或学习哈希结构，因此有可能突破某些数据无关 LSH 的限制。

从应用角度看，近似最近邻搜索也成为现代向量检索和向量数据库的重要基础。实际系统中常常结合哈希、图搜索、量化和聚类等多种技术。这说明本文的下界并不意味着近似最近邻问题无法继续改进，而是提醒我们：如果仍然限制在标准 LSH 模型内，已有结果已经接近理论边界；若要得到更强性能，往往需要改变模型假设或使用其他类型的数据结构。

5 论文提出了什么技术

5.1 LSH 的基本形式

设 (X, d_X) 是一个度量空间。随机哈希函数族 $H : X \rightarrow \mathbb{N}$ 称为 (r, R, p, q) -sensitive，如果对任意 $x, y \in X$ ，有

$$d_X(x, y) \leq r \Rightarrow \Pr_H[H(x) = H(y)] \geq p,$$

并且

$$d_X(x, y) > R \Rightarrow \Pr_H[H(x) = H(y)] \leq q.$$

在近似最近邻问题中通常令 $R = cr$ ，并用

$$\rho = \frac{\log(1/p)}{\log(1/q)}$$

衡量 LSH 的效率。这里 p 越大，说明近点越容易被放到同一个桶中； q 越小，说明远点越不容易误碰撞。因此，一个好的 LSH 需要同时做到“近点高碰撞”和“远点低碰撞”。本文的技术正是围绕这两个要求之间的矛盾展开。

5.2 论文的核心技术路线

论文没有直接分析整个高维 ℓ_s^d 空间，而是先分析它的一个特殊子集：

$$\{0, 1\}^d.$$

这个集合是 Hamming 立方体。在该集合上，两个点之间的 ℓ_1 距离等于它们不同坐标的个数。

选择 Hamming 立方体的好处是，它既足够简单，又保留了高维空间的核心困难。立方体中每个点都是一个 0-1 向量，距离就是不同坐标的数量；同时，从一个点出发随机翻转坐标，就得到一个非常自然的随机游走过程。论文正是利用这个随机游走来刻画“从一个点移动到附近点”时哈希值是否仍然相同。

更具体地说，论文把证明分成三层。

第一层是哈希桶分析。固定一个点 x ，所有与 x 哈希到同一个值的点构成集合

$$A = H^{-1}(H(x)).$$

这个集合就是 x 所在的哈希桶。远点低碰撞条件说明：如果一个点离 x 很远，它落入同一桶的概率至多是 q 。因此，哈希桶不能在整个 Hamming 立方体中占据太大比例；否则远点之间同桶的概率会过高。

第二层是随机游走分析。论文考虑从桶中的点出发，在 Hamming 立方体上随机走 r 步。由于每一步只翻转一个坐标，终点与起点的 Hamming 距离不会超过 r 。如果 H 真的是一个好的 LSH，那么这些近点应当有较大概率仍然落在同一个桶中，也就是随机游走应当有较大概率从 A 出发后仍回到 A 。

第三层是小集合扩散性质。Hamming 立方体上的随机游走会扩散：如果集合 A 很小，那么从 A 中出发的随机游走很难在若干步之后仍然停留在 A 中。这与 LSH 要求的近点高碰撞形成冲突。论文通过傅里叶分析给出这一随机游走概率的上界，并把它与哈希桶大小的上界结合，得到核心不等式

$$p \leq \left(q + \exp \left(-\frac{1}{d} \left(\frac{d}{2} - R \right)^2 \right) \right)^{\frac{e^{2r/d-1}}{e^{2r/d+1}}}.$$

这个不等式说明，只要远点碰撞概率 q 很小，近点碰撞概率 p 也会被迫受到限制。最后再把 Hamming 立方体看作 ℓ_s^d 的子集，就可以把该下界推广到高维 ℓ_s 空间。

6 技术背后的直觉

可以把一个哈希值对应的所有点看成一个桶。若远点碰撞概率 q 很小，那么一个桶不能包含太多彼此相距很远的点；否则随机选两个点时，它们同桶且相距较远的概率会过大，违反 LSH 的远点条件。

另一方面，近点碰撞概率 p 要求相近的点经常落入同一个桶。论文考虑从某个点出发，在 Hamming 立方体上随机走若干步。如果起点在某个桶中，且终点仍在这个桶中，那么这对应一

种近点碰撞事件。随机游走的扩散性质说明：如果桶不大，随机游走很难长时间留在桶中。因此 p 也不能太大。

这就是证明的核心冲突：

远点低碰撞要求桶不能太大 + 小桶难以困住随机游走 $\Rightarrow$ 近点碰撞概率存在上限。

[TODO: 补充一个简单例子，说明为什么小集合在 Hamming 立方体上容易被随机游走走出。]

7 技术的非凡之处与好处

这篇论文的巧妙之处在于，它没有逐个分析具体的 LSH 构造，而是从 LSH 定义本身出发，证明所有满足该定义的哈希族都受到同一个限制。这使得结论具有模型层面的普遍性。

另一个优点是，论文把一个算法问题转化成了 Hamming 立方体上的几何和概率问题。通过哈希桶、随机游走和集合扩散性质，作者把“近点要高碰撞、远点要低碰撞”的直觉冲突变成了可量化的不等式。

[TODO: 补充：为什么这种证明比只分析某个具体算法更强。]

8 技术是如何实现的

8.1 第一步：限制哈希桶大小

固定一个哈希函数和一个点 $x \in \{0, 1\}^d$ ，令

$$A = H^{-1}(H(x)).$$

集合 A 是与 x 哈希到同一个值的所有点。远点碰撞概率小意味着：如果某些点与 x 距离大于 R ，它们落入同一个桶的概率不能超过 q 。

[TODO: 详细写出如何由远点条件推出桶大小或桶内远点比例的期望上界。]

8.2 第二步：用随机游走连接近点碰撞

在 Hamming 立方体上，从点 x 出发随机翻转一个坐标，重复 r 次。若 r 为奇数，则起点和终点之间的 Hamming 距离不超过 r 。因此，LSH 的近点条件给出：

$$\Pr[H(x) = H(y)] \geq p.$$

也就是说，随机游走从桶 A 出发后仍留在 A 的概率至少受到 p 的控制。

[TODO: 补充论文中对随机游走步数、距离条件和碰撞概率之间关系的严格表述。]

8.3 第三步：用小集合扩散性质给出上界

Hamming 立方体上的随机游走具有扩散性：如果集合 A 不够大，随机游走从 A 中出发后仍留在 A 中的概率不会太高。论文用这一性质得到核心命题：

$$p \leq \left(q + \exp \left(-\frac{1}{d} \left(\frac{d}{2} - R \right)^2 \right) \right)^{\frac{e^{2r/d} - 1}{e^{2r/d} + 1}}.$$

[TODO: 解释该式中每一项的含义，特别是 q 、指数误差项和幂指数分别来自哪里。]

8.4 第四步：从 Hamming 立方体推广到 ℓ_s 空间

由于 $\{0,1\}^d$ 可以看作 ℓ_s^d 的子集，并且在 0-1 向量上距离满足

$$\|x - y\|_s = \|x - y\|_1^{1/s},$$

Hamming 距离上的下界可以转化为 ℓ_s 空间中的下界。最终得到：

$$\rho_s(c) \geq \frac{e^{1/c^s} - 1}{e^{1/c^s} + 1} \geq \frac{0.462}{c^s}.$$

[TODO: 补充参数替换过程，说明为什么近似因子从 Hamming 距离中的关系变成了 c^s 。]

9 如何证明技术的正确性

证明正确性的关键是逐步确认每个转化都保持了 LSH 定义中的约束：

1. 哈希桶分析没有改变哈希族本身，只是从碰撞事件 $H(x) = H(y)$ 的角度重新表达 LSH 条件；
2. 远点条件确实给出桶中远点数量或概率的限制；
3. 随机游走终点与起点距离不超过指定阈值，因此可以使用近点碰撞概率下界；
4. Hamming 立方体的小集合扩散性质给出随机游走留在同一集合内的上界；
5. 上下界比较后推出 p 的上界，再代入 $\rho = \log(1/p)/\log(1/q)$ 得到 ρ 的下界；
6. Hamming 立方体作为 ℓ_s^d 的子集，因此子空间上的困难性可以推出整个空间上的困难性。

[TODO: 把上述每一点展开成正式证明，尤其要写清楚“为什么随机游走终点是近点”和“为什么子空间下界能推出整体空间下界”。]

10 如何证明技术的优越性

论文证明的不是某个具体算法优于另一个算法，而是证明已有 LSH 上界在量级上无法被显著改进。已有 LSH 构造给出了大约 $O(1/c^s)$ 量级的 ρ ，而本文证明任何 LSH 都必须满足

$$\rho_s(c) = \Omega(1/c^s).$$

因此，上界和下界在渐近量级上匹配。

这种“优越性”体现在两个方面：第一，它说明已有算法已经接近最优，不需要再期待在同一 LSH 模型内得到数量级更好的 ρ ；第二，它提供了一种评价未来算法的基准，如果想显著突破该限制，可能需要改变模型假设或使用 LSH 之外的方法。

[TODO: 补充具体已有上界，与本文下界放在同一段比较，说明匹配到什么程度。]

11 总结

[TODO: 用自己的话总结：本文解决了什么问题，技术直觉是什么，证明为什么可信，以及这个下界结果对 LSH 研究有什么意义。]

参考文献

- [1] R. Motwani, A. Naor, and R. Panigrahy. Lower Bounds on Locality Sensitive Hashing. *Proceedings of the Twenty-second Annual Symposium on Computational Geometry*, 2006.
- [2] P. Indyk and R. Motwani. Approximate Nearest Neighbors: Towards Removing the Curse of Dimensionality. *Proceedings of STOC*, 1998.
- [3] M. Datar, N. Immorlica, P. Indyk, and V. S. Mirrokni. Locality-Sensitive Hashing Scheme Based on p-Stable Distributions. *Proceedings of the Twentieth Annual Symposium on Computational Geometry*, 2004.
- [4] A. Andoni and P. Indyk. Faster Algorithms for High-Dimensional Nearest Neighbor Search. Manuscript, 2005.